Visualización de datos

Outline

- Buenos gráficos – el “lie factor”
- Representar datos en 1,2, y 3-D
- Representar datos en 4+ dimensiones
  - Parallel coordinates
  - Scatterplots
  - Stick figures

Rol de la visualización

- Soporte de la exploración interactiva
- Ayuda a la presentación de resultados

- Contra: Puede llevar a confusiones, ser engañosas

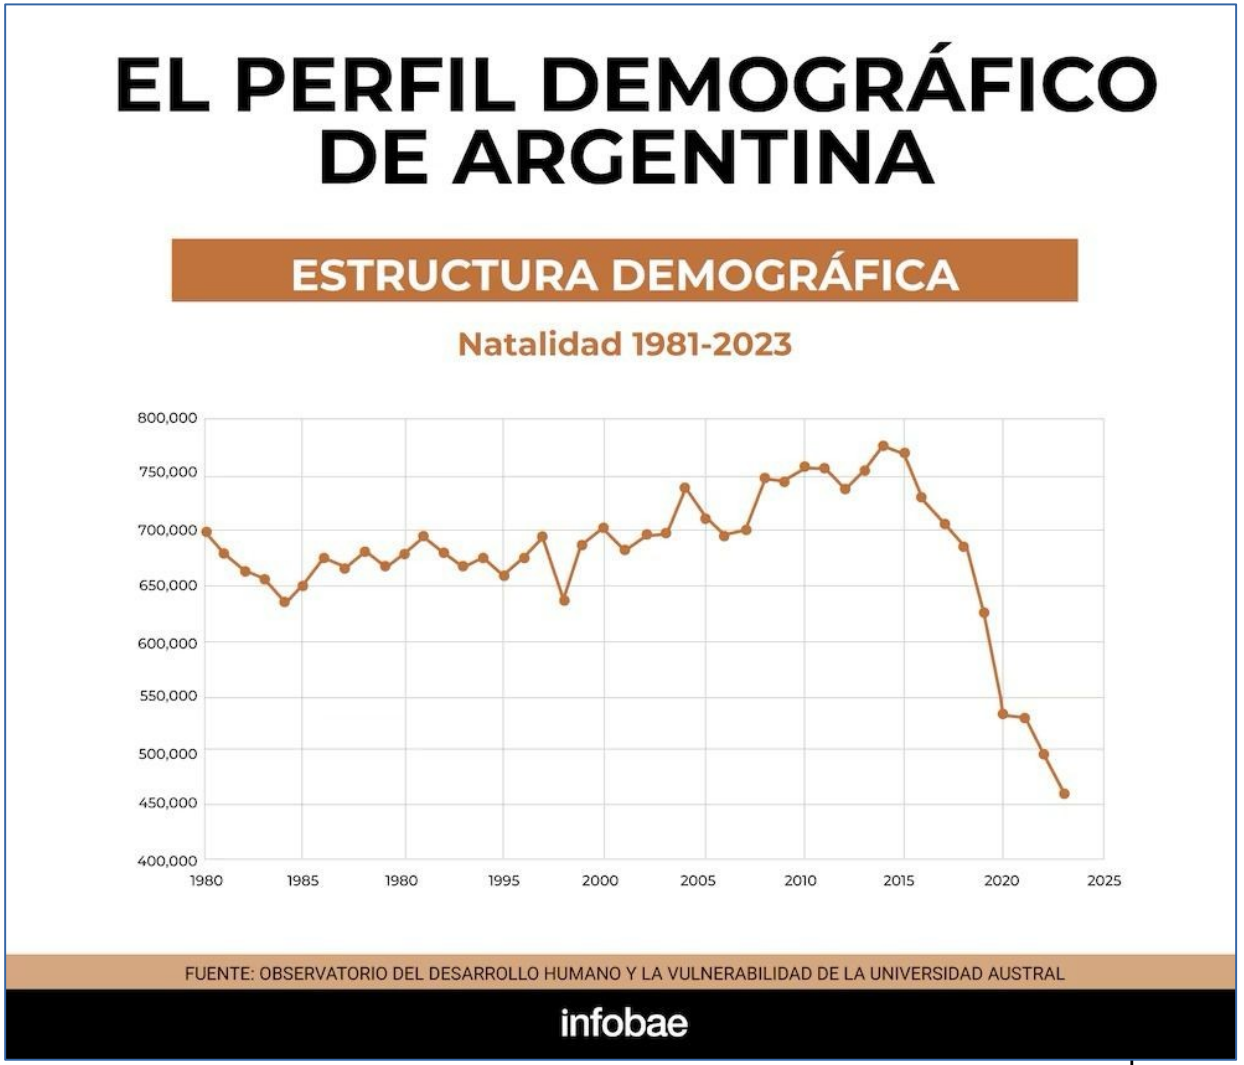
Rol de la visualización

- Soporte de la exploración interactiva
- Ayuda a la presentación de resultados



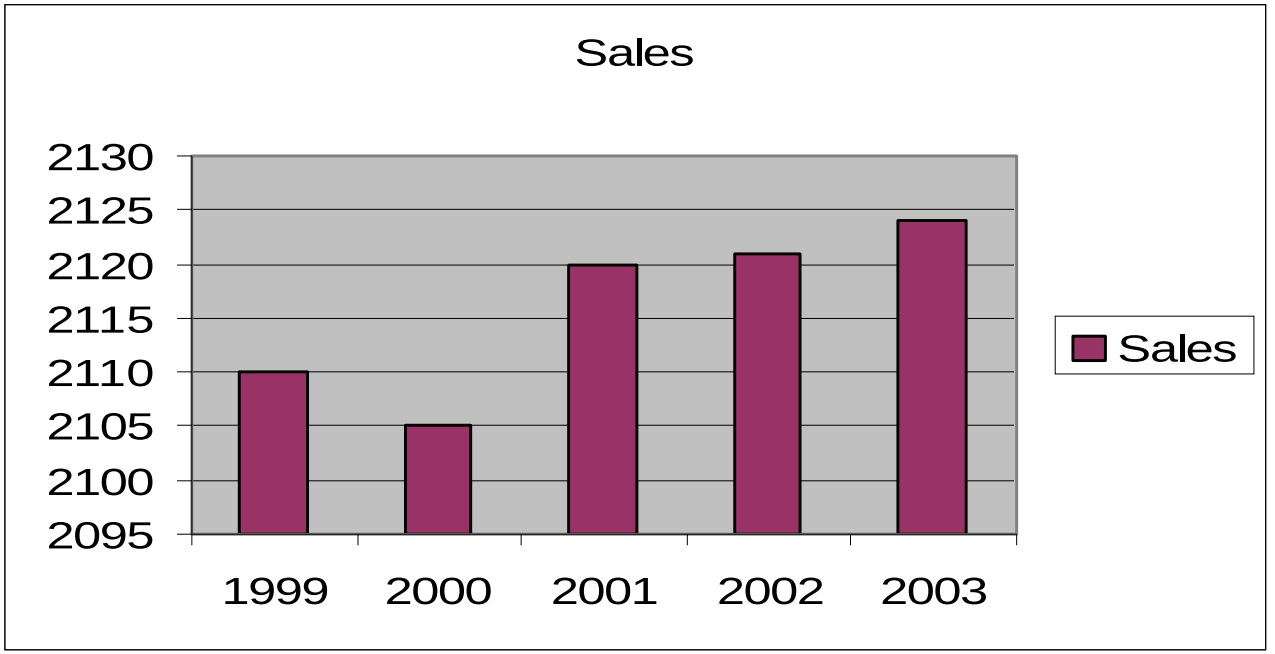
- Contra: Puede llevar a confusiones, ser engañosas

Malas figuras

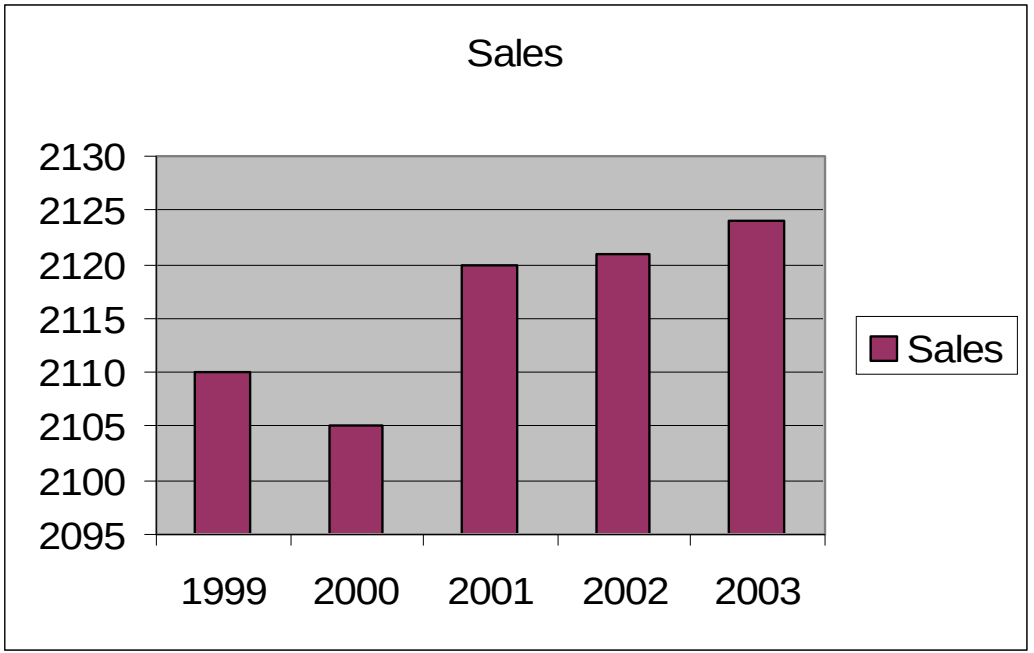


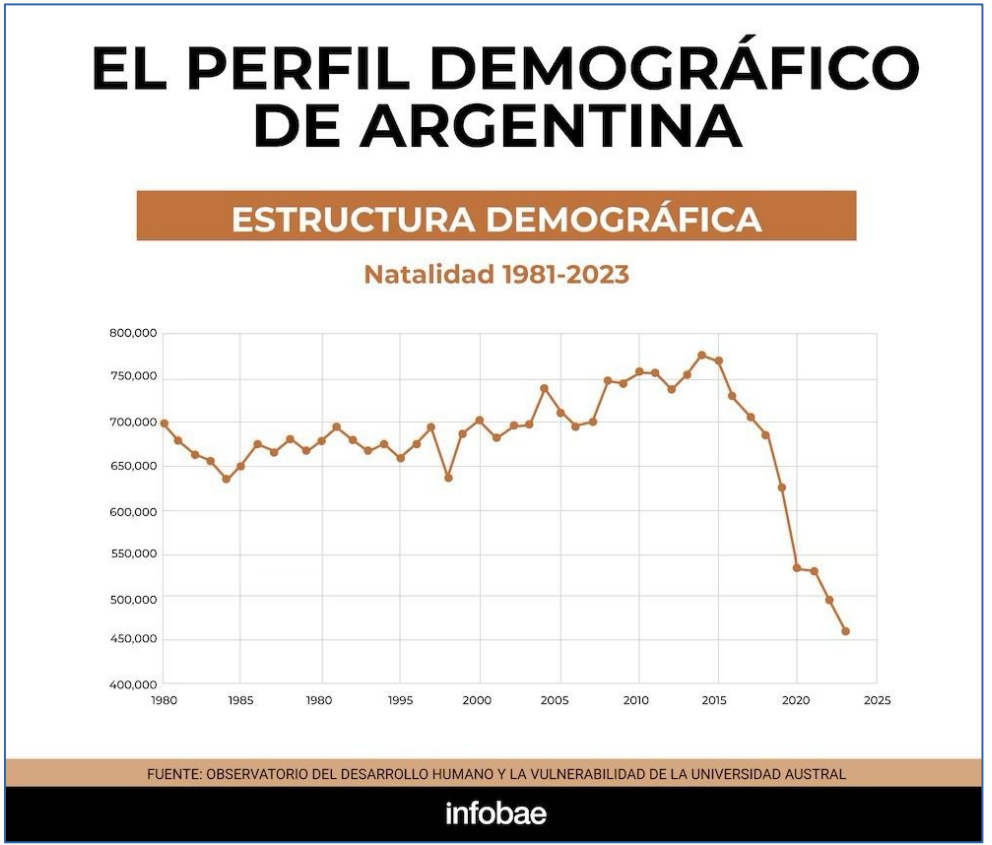
Malas figuras: Spreadsheet

Year	Sales
1999	2,110
2000	2,105
2001	2,120
2002	2,121
2003	2,124



Malas figuras

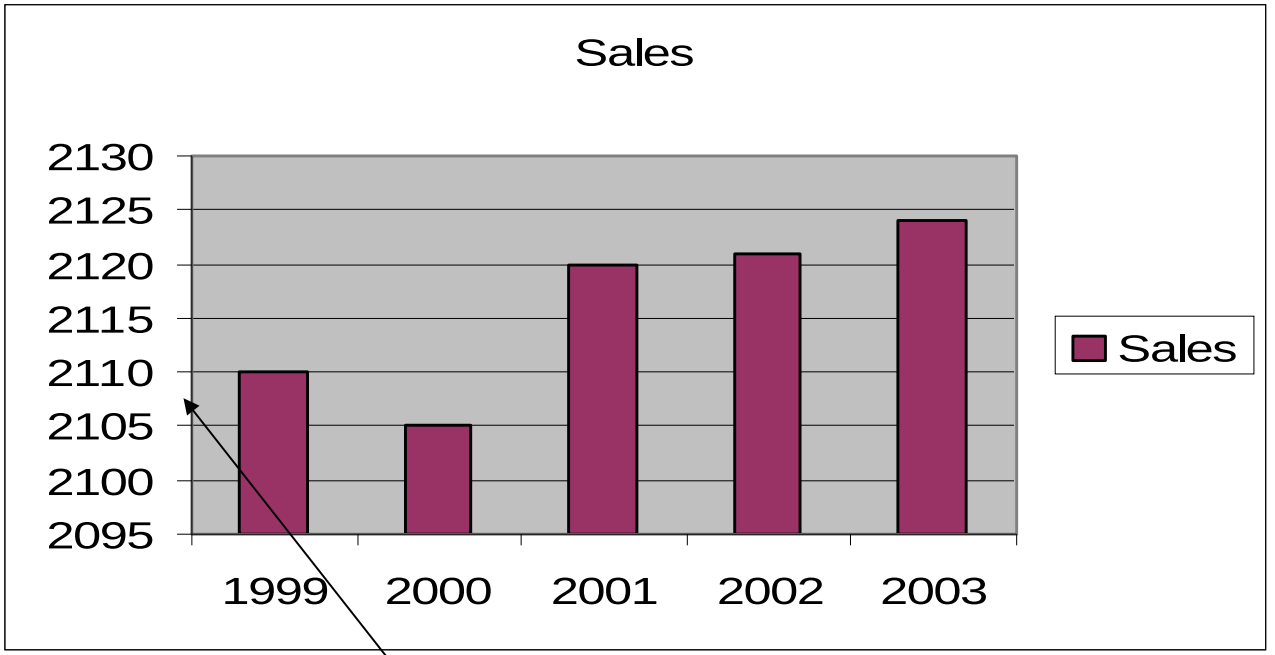




¿Qué está mal en estas figuras?

Malas figuras: Spreadsheet con eje vertical engañoso

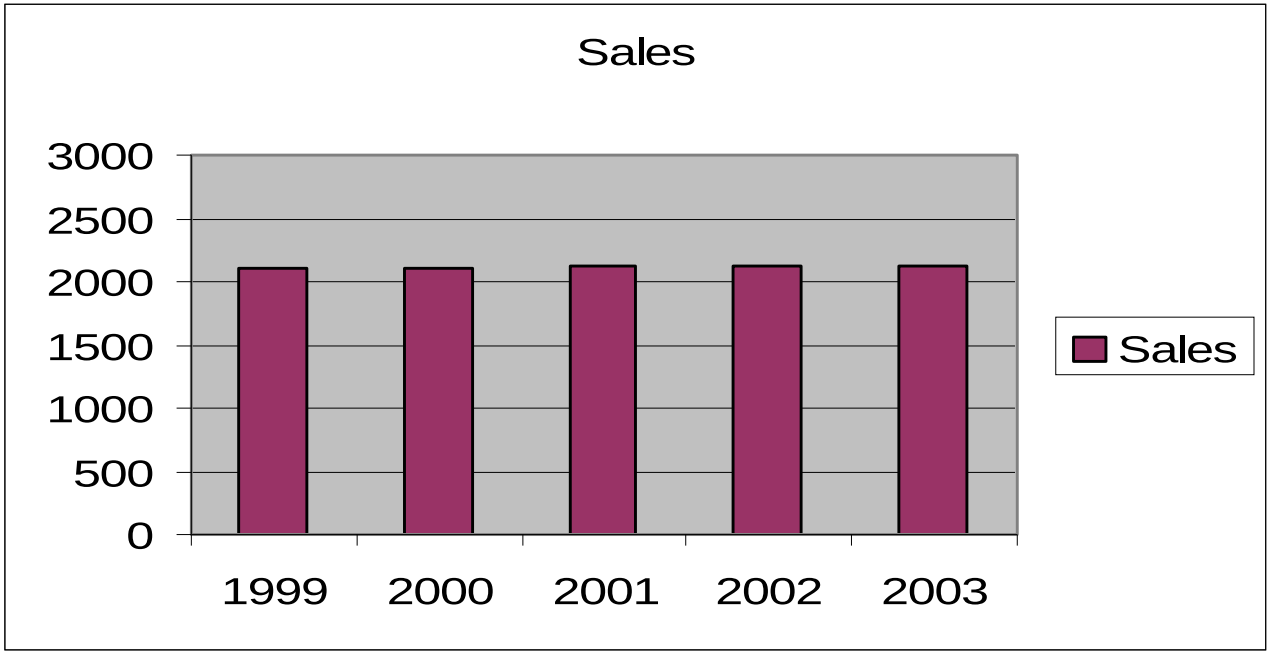
Year	Sales
1999	2,110
2000	2,105
2001	2,120
2002	2,121
2003	2,124



La escala del eje Y da la impresión **INCORRECTA** de un gran efecto

Una mejor figura

Year	Sales
1999	2,110
2000	2,105
2001	2,120
2002	2,121
2003	2,124



La escala de 0 a 2000 da la correcta impresión de mínimo efecto

Lie Factor

$$Lie\ \ Factor = \frac{size\ \ of\ \ effect\ \ shown\ in\ \ graphic}{size\ \ of\ \ effect\ \ in\ \ data} =$$

(E.R. Tufte, "The Visual Display of Quantitative Information", 2nd edition)

Lie Factor

$$Lie\ \ Factor = \frac{size\ \ of\ \ effect\ \ shown\ in\ \ graphic}{size\ \ of\ \ effect\ \ in\ \ data} =$$

$$= \frac{\frac{(29-11)}{11}}{\frac{(2124-2105)}{2105}} = \frac{1.636}{0.009} = 181.2$$

(E.R. Tufte, "The Visual Display of Quantitative Information", 2nd edition)

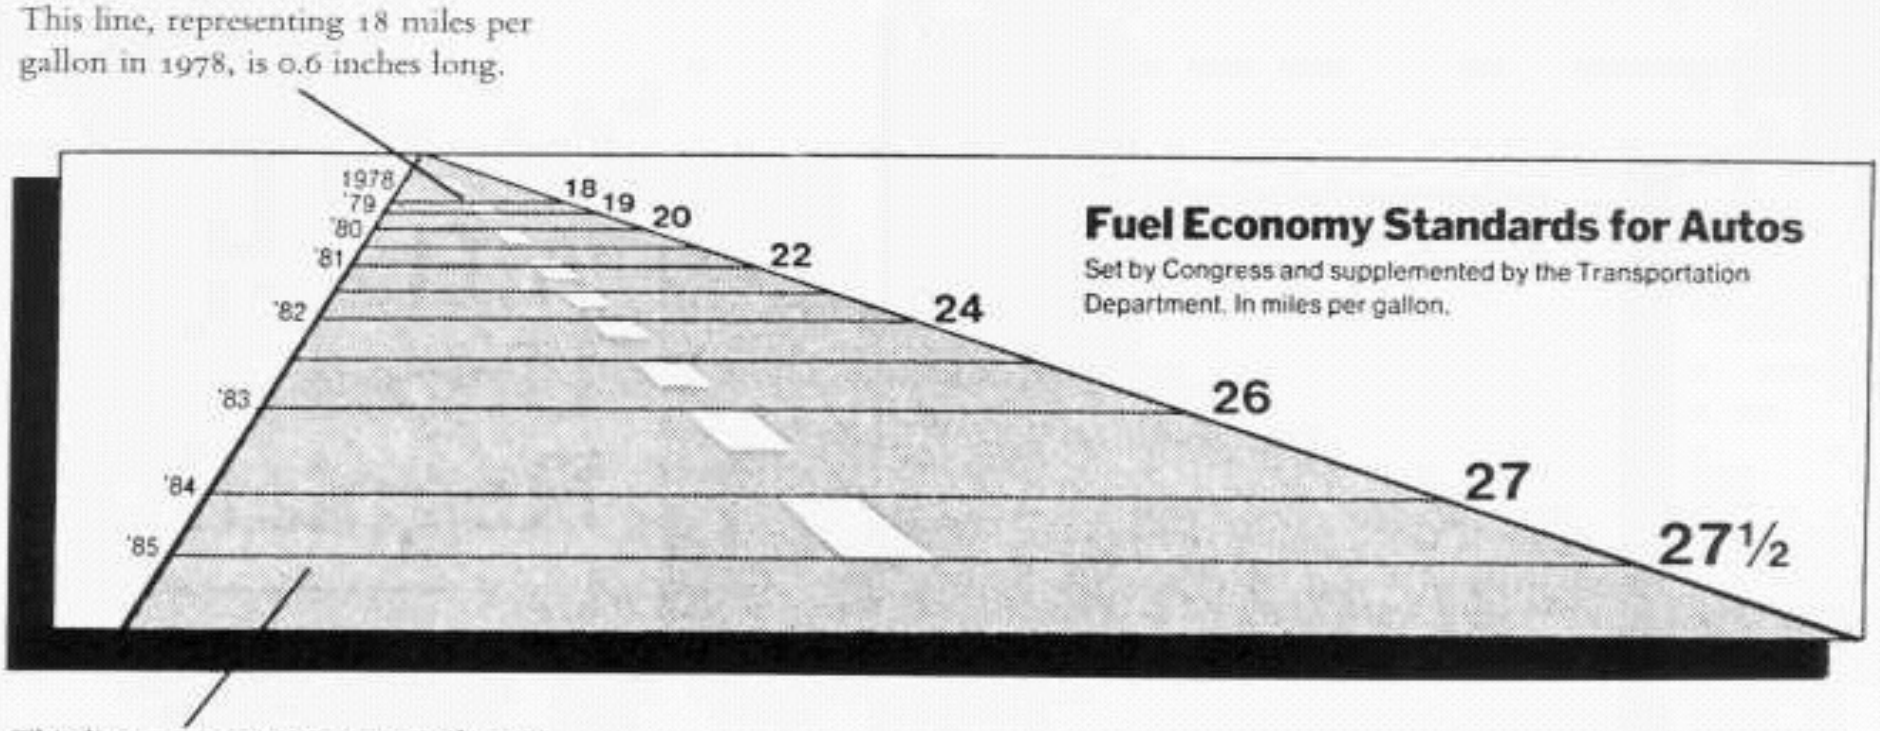
Lie Factor

$$Lie\ \ Factor = \frac{size\ \ of\ \ effect\ \ shown\ in\ \ graphic}{size\ \ of\ \ effect\ \ in\ \ data} =$$

$$= \frac{\frac{(29-11)}{11}}{\frac{(2124-2105)}{2105}} = \frac{1.636}{0.009} = 181.2$$

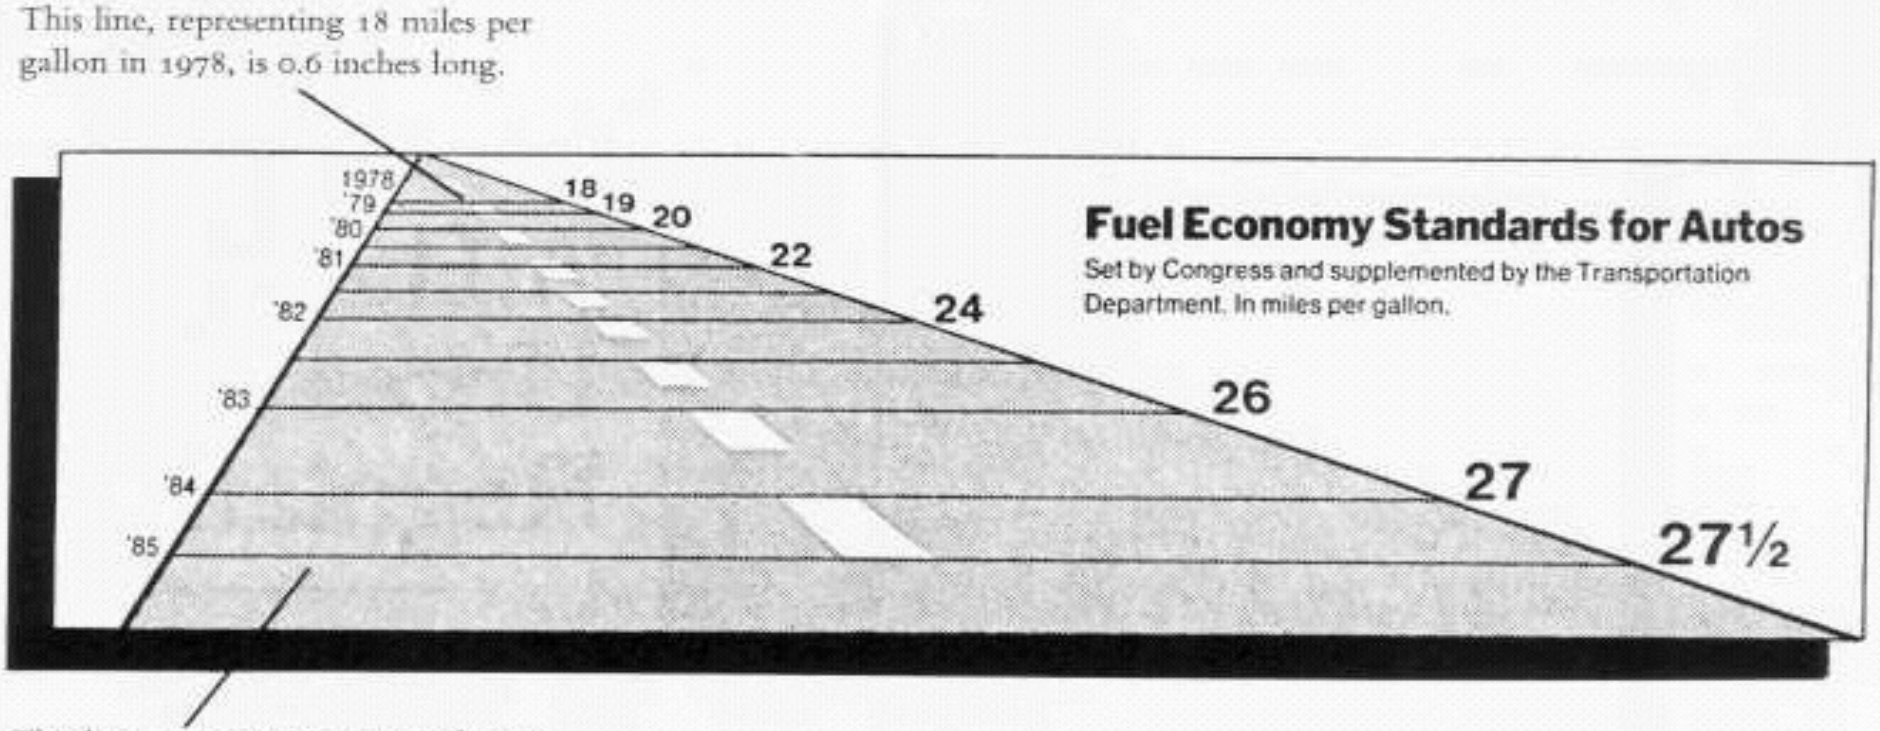
Requerido por Tufte: 0.95<Lie Factor<1.05

(E.R. Tufte, "The Visual Display of Quantitative Information", 2nd edition)



New York Times, August 9, 1978, p. D-2.

(E.R. Tufte, "The Visual Display of Quantitative Information", 2nd edition)



Lie Factor=14.8

New York Times, August 9, 1978, p. D-2.

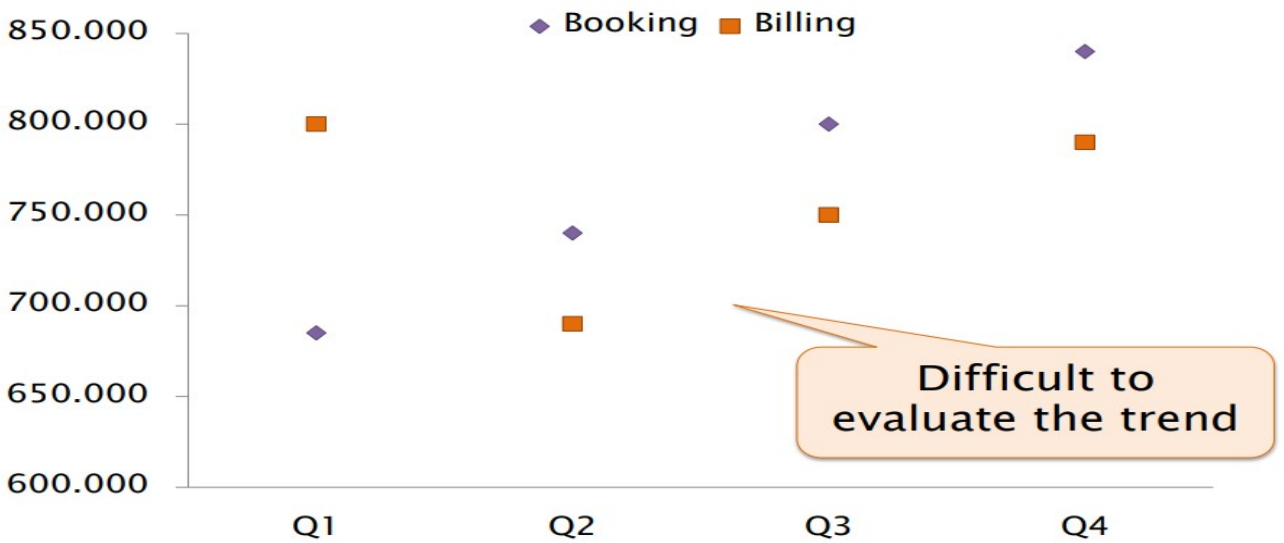
(E.R. Tufte, "The Visual Display of Quantitative Information", 2nd edition)

Ayudar a la comprensión

- Reglas culturales: Izquierda a derecha, arriba hacia abajo
- Enfatizar el efecto, ayudas visuales

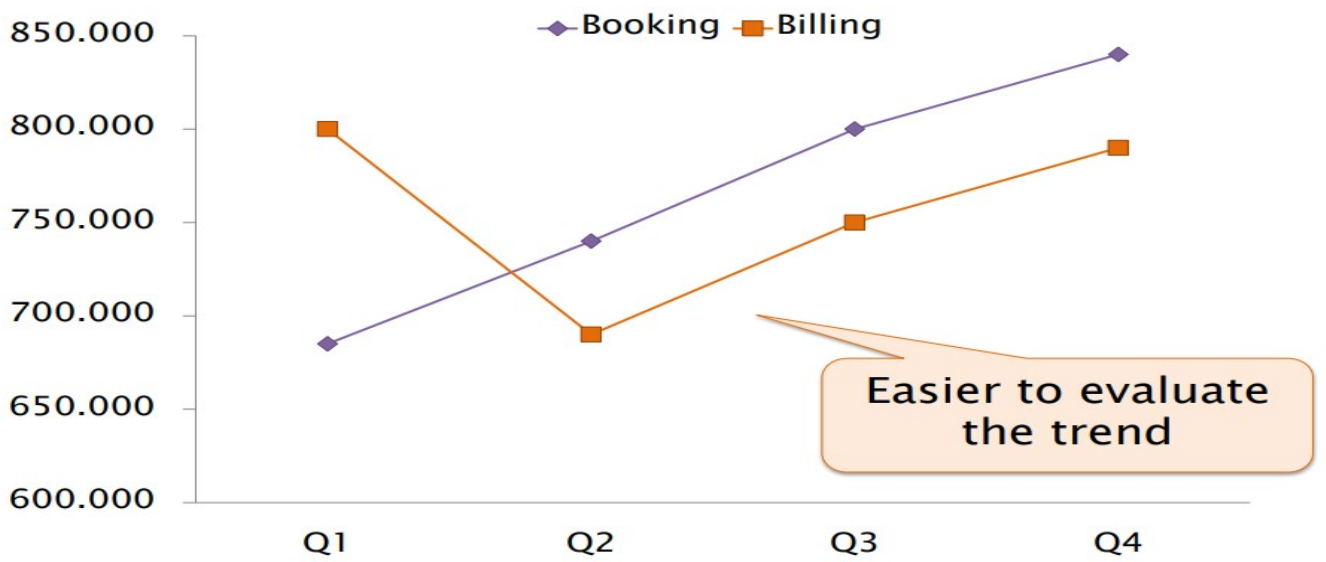
Ayudar a la comprensión

- Reglas culturales: Izquierda a derecha, arriba hacia abajo
- Enfatizar el efecto, ayudas visuales



Ayudar a la comprensión

- Reglas culturales: Izquierda a derecha, arriba hacia abajo
- Enfatizar el efecto, ayudas visuales

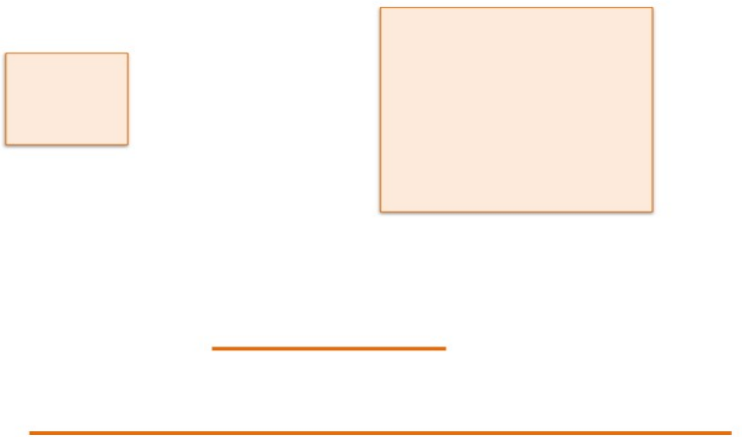


Ayudar a la comprensión

- Reglas culturales: Izquierda a derecha, arriba hacia abajo
- Enfatizar el efecto, ayudas visuales
- Facilitar la percepción
  de las diferencias

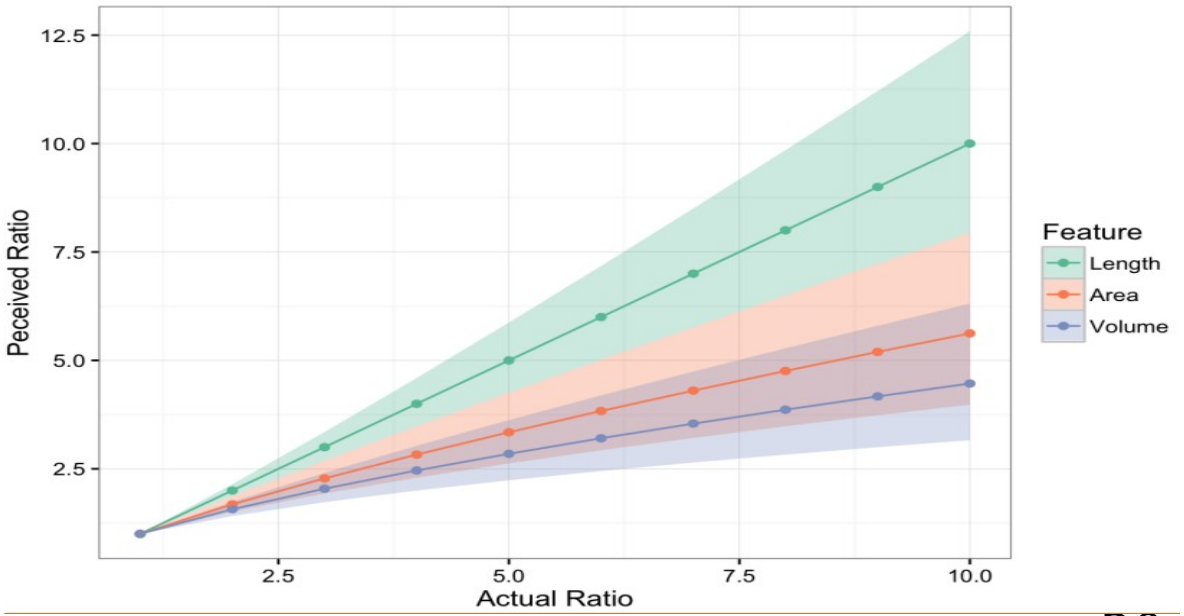
Ayudar a la comprensión

- Reglas culturales: Izquierda a derecha, arriba hacia abajo
- Enfatizar el efecto, ayudas visuales
- Facilitar la percepción
  de las diferencias



Ayudar a la comprensión

- Reglas culturales: Izquierda a derecha, arriba hacia abajo
- Enfatizar el efecto, ayudas visuales
- Facilitar la percepción de las diferencias



Pensar el mensaje

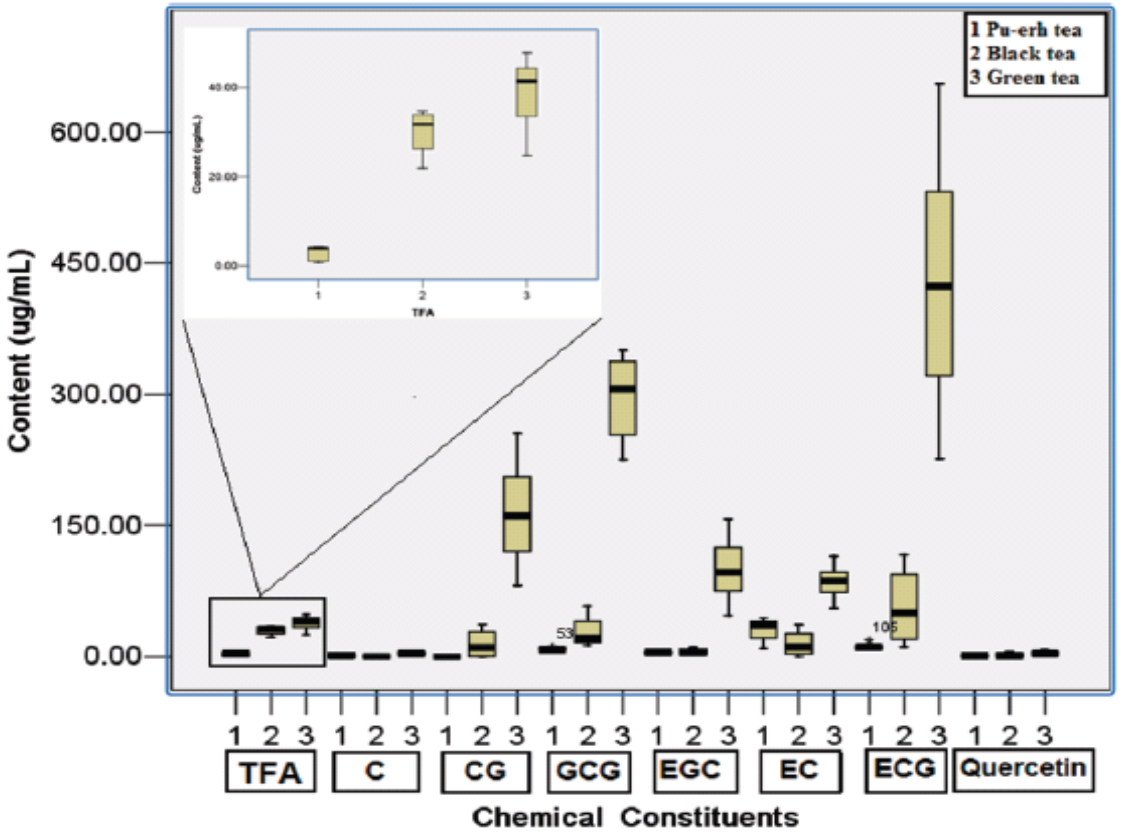


Figure 3. The contents of TFA, C, CG, GCG, EGC, EC, ECG, and quercetin in pu-erh teas, black teas, and green teas.

Tufte: Principios de las buenas visualizaciones

- Darle al observador
  - el mayor número de ideas
  - en el menor tiempo
  - con la menor cantidad de tinta y espacio.

- Decir la verdad sobre los datos!

(E.R. Tufte, "The Visual Display of Quantitative Information", 2nd edition)

Rol de la visualización

- Soporte de la exploración interactiva
- Ayuda a la presentación de resultados



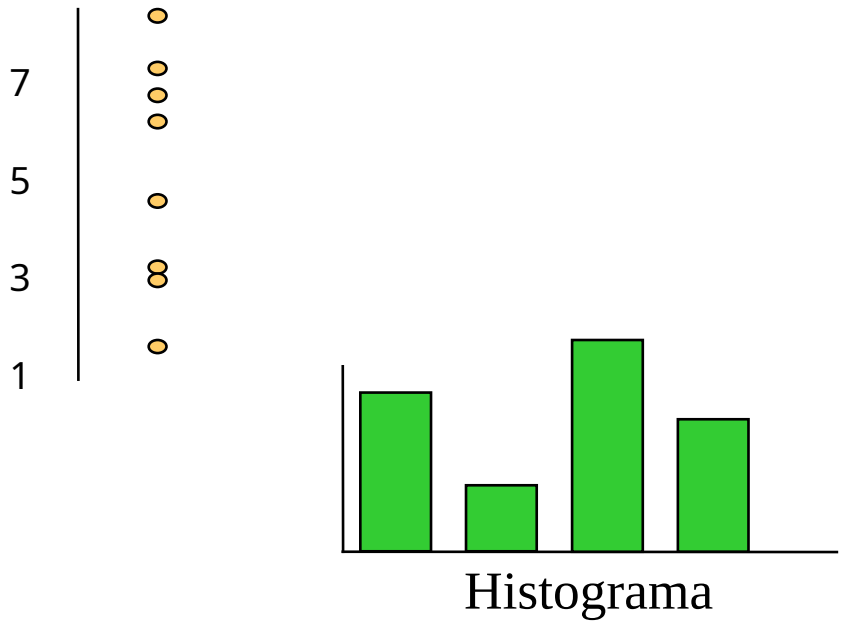
- Contra: Puede llevar a confusiones, ser engañosas

Métodos de Visualización

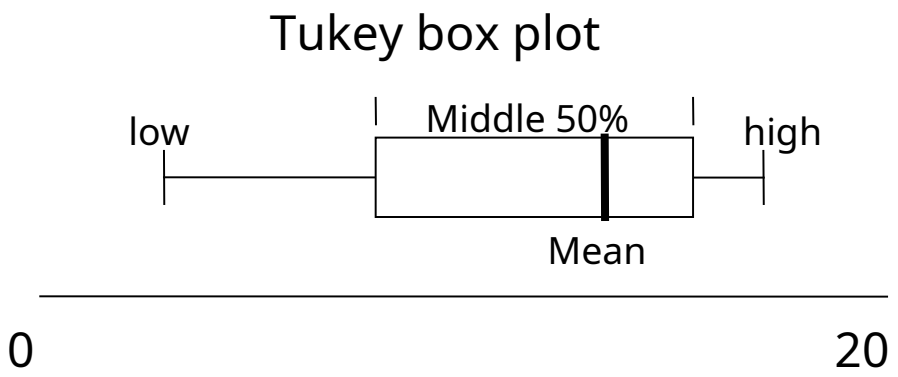
- Visualización en 1-D, 2-D y 3-D
  - Métodos simples y conocidos
- Visualización en más dimensiones
  - Parallel Coordinates
  - Símbolos
  - Otras ideas

Datos 1-D (Univariados)

- Representaciones



Histograma



R: ejemplos

```
x<-c(10,runif(99))

plot(x)

plot(x,rep(0,100))

hist(x)

# se ve el outlier, pero en muchos datos se puede
  perder

x<-c(10,rnorm(9999))

hist(x)

# con boxplot se ve el outlier siempre, pero se pierde
  información de la distribución

boxplot(x)

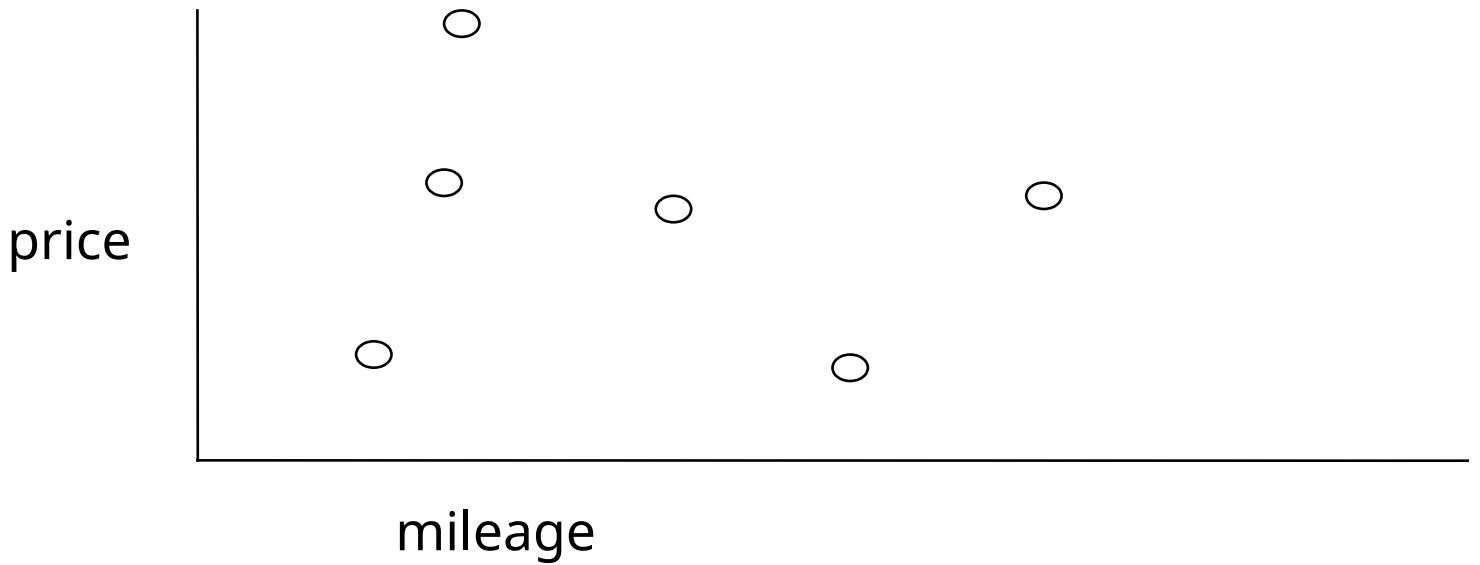
boxplot(x,range=2)
```

Python: ejemplos

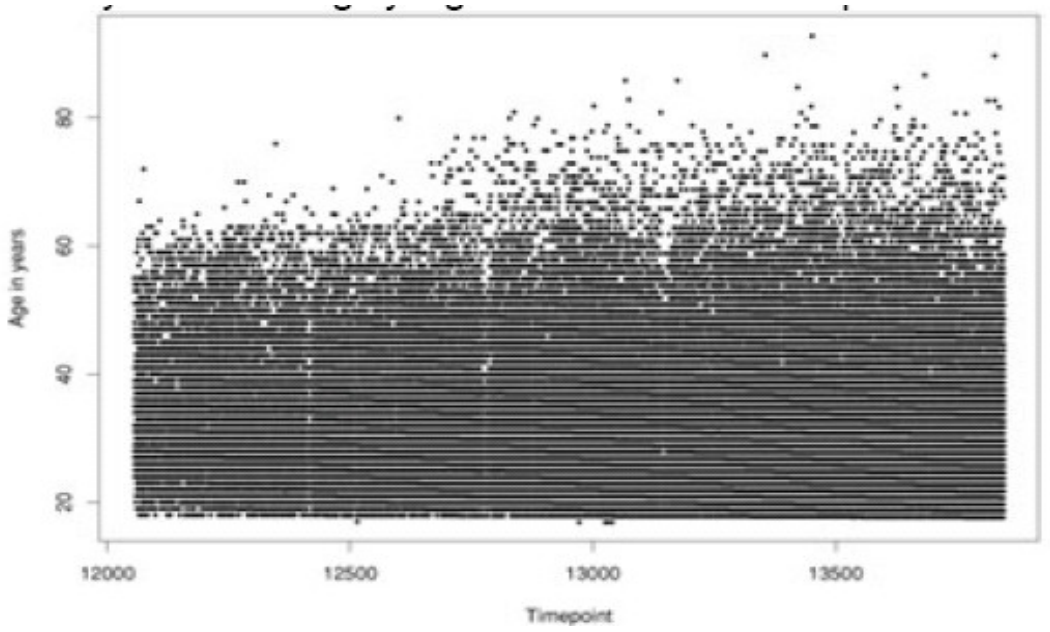
```
import numpy as np
import matplotlib.pyplot as plt
# Generar datos con distribución uniforme y un outlier
x1 = np.concatenate(([10], np.random.uniform(size=99)))
# Gráfico de dispersión (puntos)
plt.plot(x1)
plt.title("plot(x)")
plt.show()
# Gráfico de dispersión contra cero (eje Y en 0)
plt.plot(x1, np.zeros(100), "o")
plt.title("plot(x, rep(0, 100))")
plt.show()
# Histograma
plt.hist(x1)
plt.title("hist(x) - Uniforme")
plt.show()
# Generar datos con distribución normal y un outlier
# (se ve el outlier, pero en muchos datos se puede perder)
x2 = np.concatenate(([10], np.random.normal(size=9999)))
plt.hist(x2)
plt.title("hist(x) - Normal")
plt.show()
# Diagrama de caja por defecto (whis=1.5 equivale al default de R)
# (con boxplot se ve el outlier siempre, pero se pierde información de la distribución)
plt.boxplot(x2)
plt.title("boxplot(x)")
plt.show()
# Diagrama de caja cambiando el alcance de los bigotes (range=2 en R equivale a whis=2 en
Python)
plt.boxplot(x2, whis=2)
plt.title("boxplot(x, whis=2)")
plt.show()
```

Datos 2-D (Bivariados)

- Scatter plot, ...



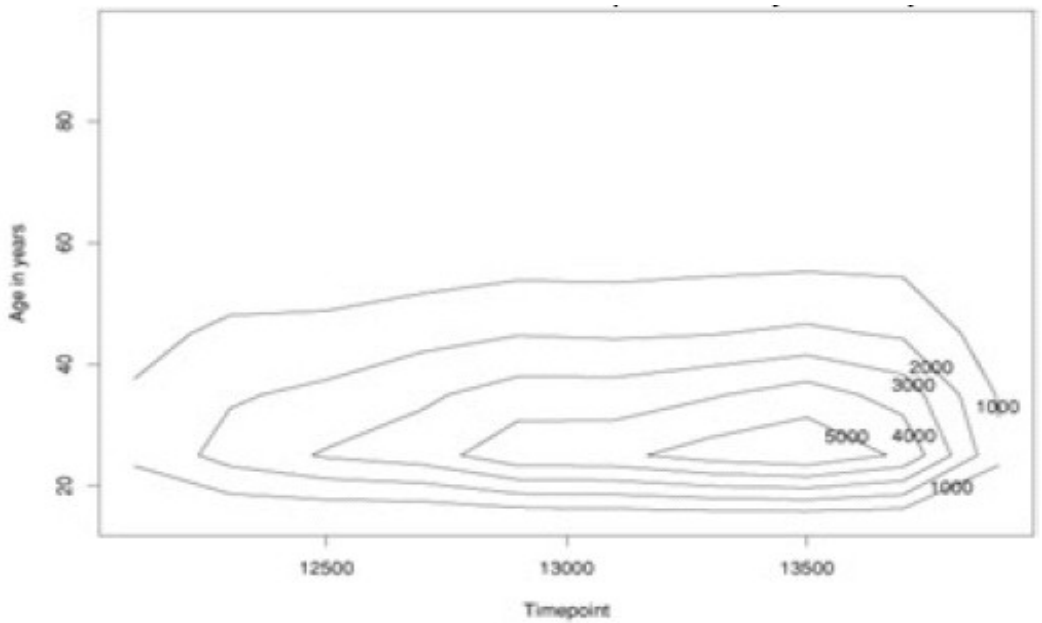
2-D: Saturación



- A veces se necesitan otros métodos

2-D: Contornos

- Apropriados para plots con alta densidad

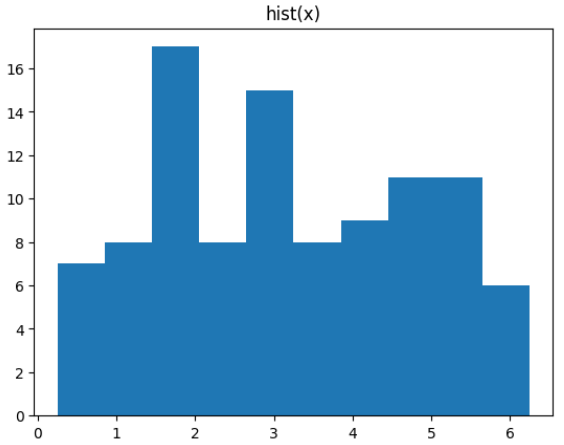


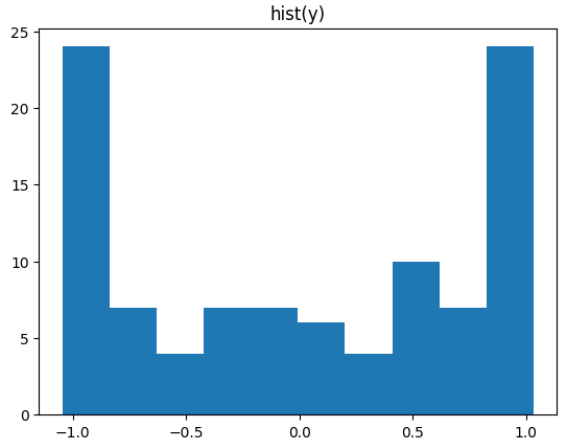
R: ejemplos

```
#dos dimensiones
x<-runif(100)*2*pi
y<-jitter(sin(x),amo=0.1)
y[c(1,100)]<-y[c(1,100)]*(-1)
hist(x)
hist(y)
boxplot(y)
plot(x,y)
```

Python: ejemplos

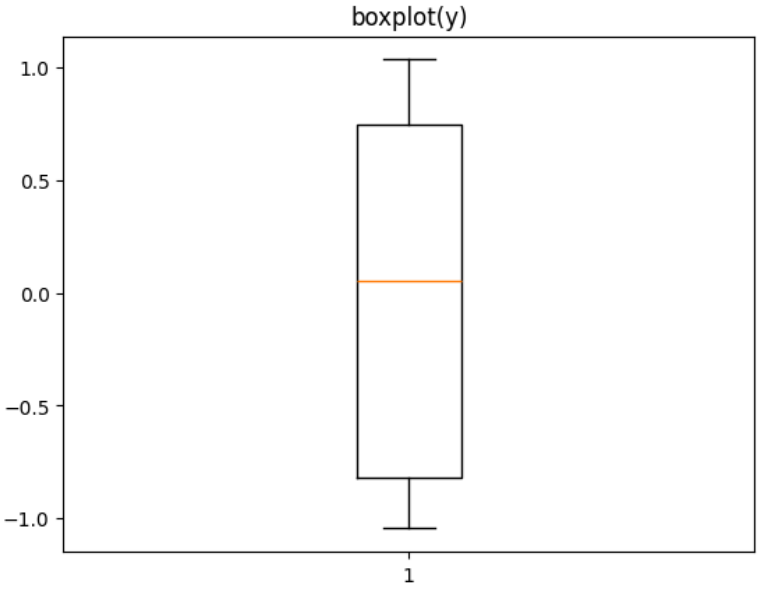
```
import numpy as np
import matplotlib.pyplot as plt
# Dos dimensiones
x = np.random.uniform(0, 1, 100) * 2 * np.pi
y = np.sin(x) + np.random.uniform(-0.05, 0.05, 100)
# Invertir el signo de los elementos en el índice 0 y 99
y[[0, 99]] = y[[0, 99]] * -1
# Histograma de X
plt.hist(x)
plt.title("hist(x)")
plt.show()
# Histograma de Y
plt.hist(y)
plt.title("hist(y)")
plt.show()
# Boxplot de Y
plt.boxplot(y)
plt.title("boxplot(y)")
plt.show()
# Gráfico de dispersión (Scatter Plot)
plt.plot(x, y, "o")
plt.title("plot(x, y)")
plt.show()
```

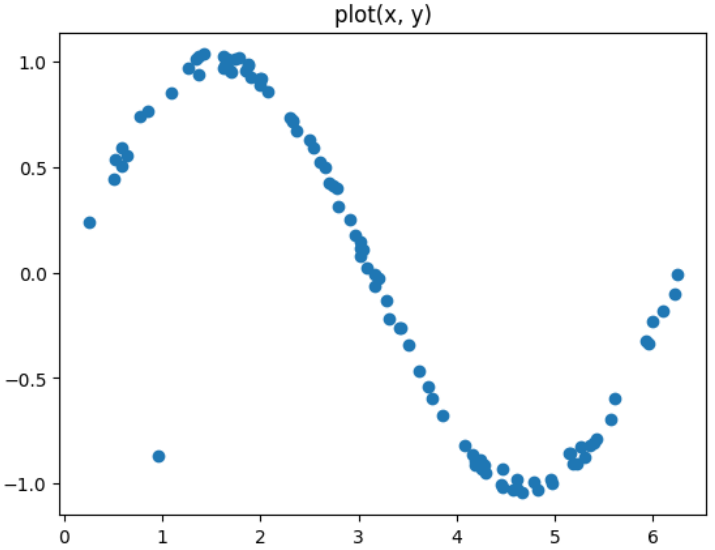




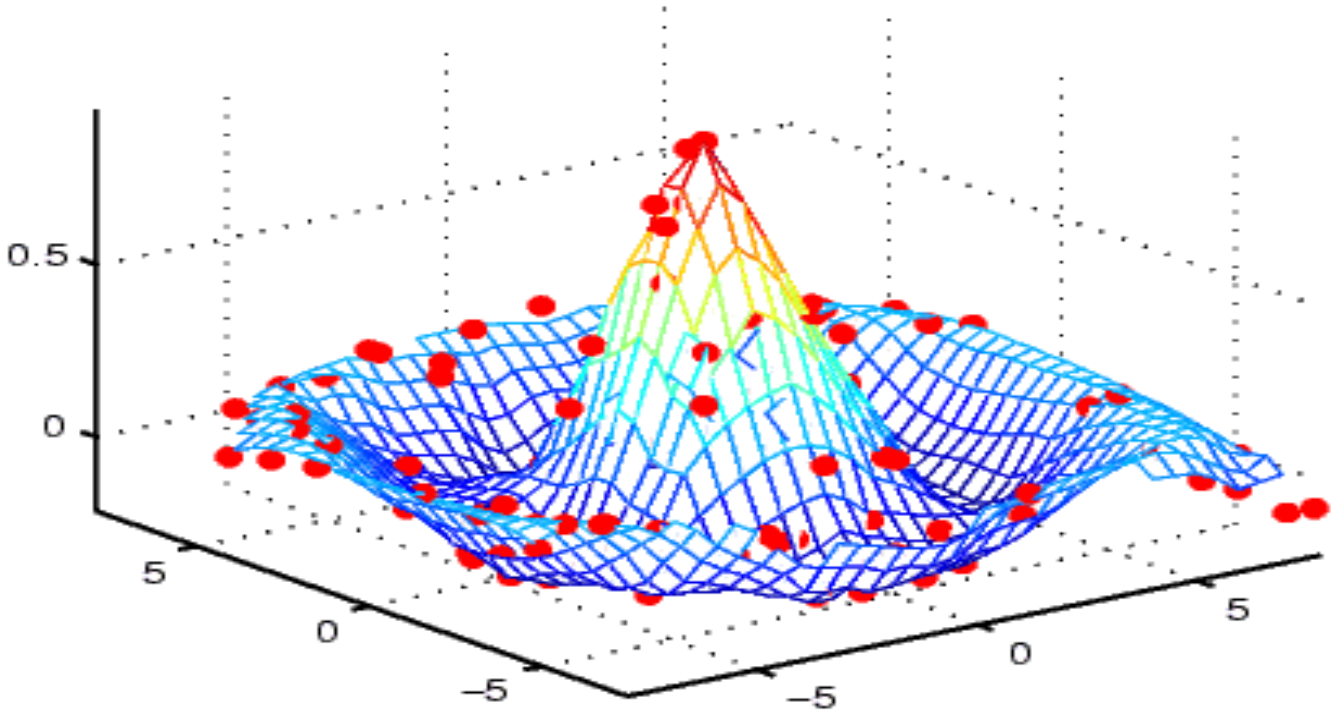
Python: ejemplos

```
import numpy as np
import matplotlib.pyplot as plt
# Dos dimensiones
x = np.random.uniform(0, 1, 100) * 2 * np.pi
y = np.sin(x) + np.random.uniform(-0.05, 0.05, 100)
# Invertir el signo de los elementos en el índice 0 y 99
y[[0, 99]] = y[[0, 99]] * -1
# Histograma de X
plt.hist(x)
plt.title("hist(x)")
plt.show()
# Histograma de Y
plt.hist(y)
plt.title("hist(y)")
plt.show()
# Boxplot de Y
plt.boxplot(y)
plt.title("boxplot(y)")
plt.show()
# Gráfico de dispersión (Scatter Plot)
plt.plot(x, y, "o")
plt.title("plot(x, y)")
plt.show()
```

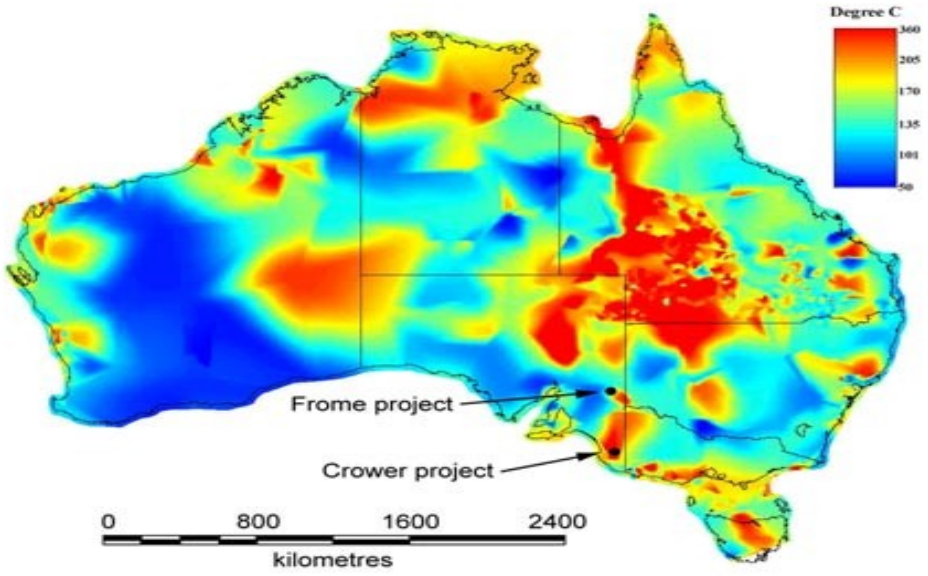


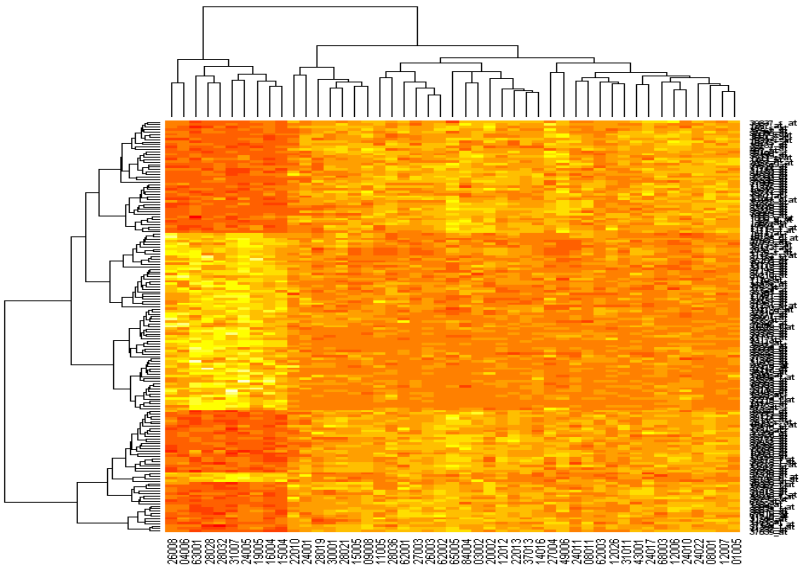


Datos 3-D (proyecciones)



Datos 3-D (heat-map)

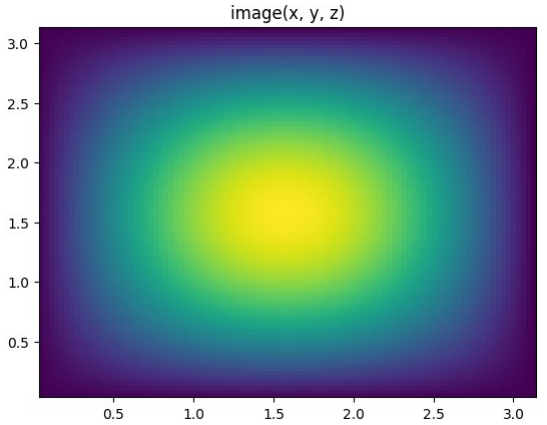




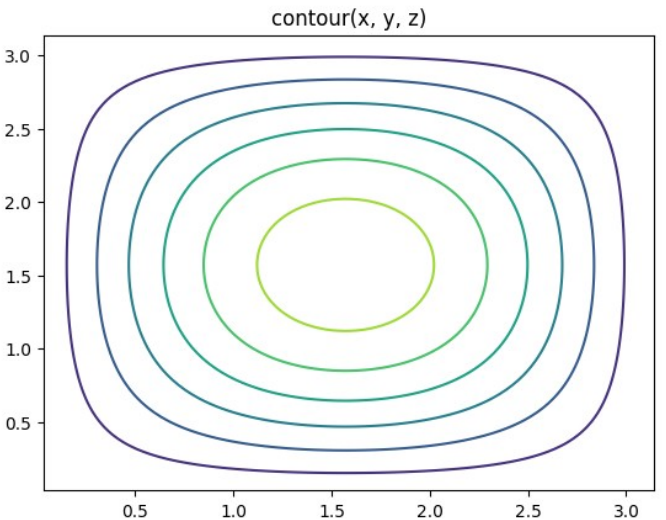
R: ejemplos

```
y<-x<-1:100*3.14/100
z<-sin(x)%*%t(sin(y))
image(x,y,z)    #heatmap
library(graphics)
contour(x,y,z)
filled.contour(x,y,z)
persp(x,y,z)
```

Python: ejemplos



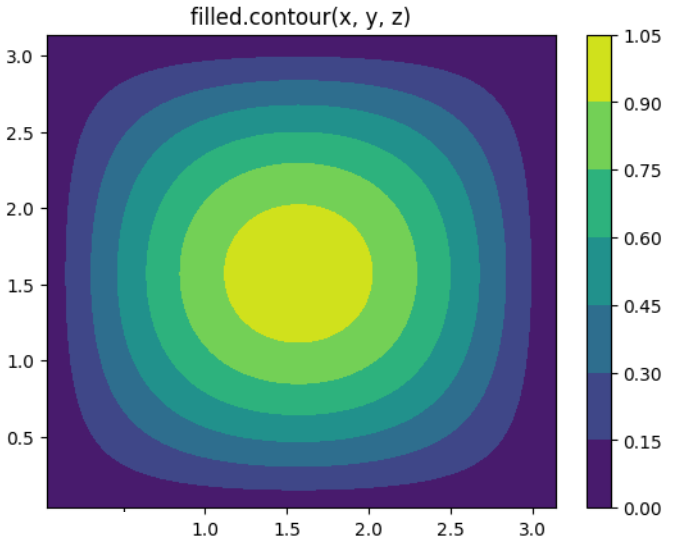

```
import numpy as np
import matplotlib.pyplot as plt
x = np.arange(1, 101) * 3.14 / 100
y = x.copy()
z = np.outer(np.sin(x), np.sin(y))
# 1. image(x, y, z) - Mapas de calor (Heatmap)
plt.imshow(z, extent=[x.min(), x.max(), y.min(), y.max()], origin="lower", aspect="auto")
plt.title("image(x, y, z)")
plt.show()
# 2. contour(x, y, z) - Líneas de nivel
plt.contour(x, y, z)
plt.title("contour(x, y, z)")
plt.show()
```

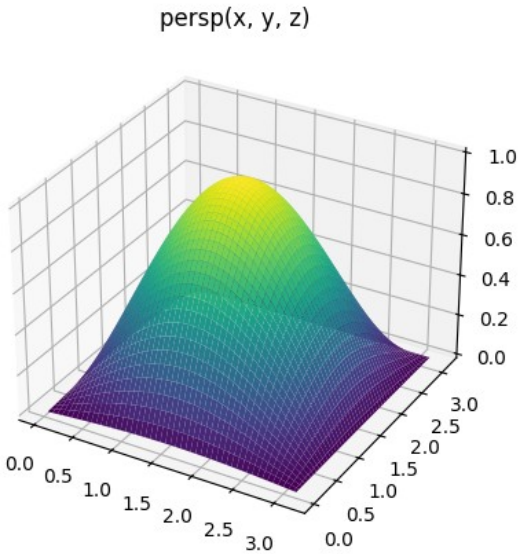


Python: ejemplos

…

```
# 3. filled.contour(x, y, z) - Contorno con relleno
plt.contourf(x, y, z)
plt.colorbar()
plt.title("filled.contour(x, y, z)")
plt.show()
# 4. persp(x, y, z) - Superficie 3D
X, Y = np.meshgrid(x, y)
fig = plt.figure()
ax = fig.add_subplot(111, projection="3d")
ax.plot_surface(X, Y, z, cmap="viridis")
plt.title("persp(x, y, z)")
plt.show()
```





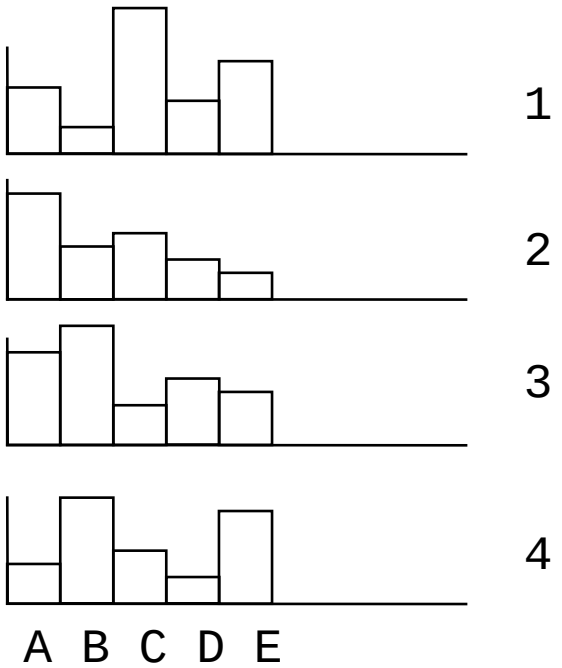
Visualización en más dimensiones

- Scatterplots
- Parallel Coordinates
- Chernoff faces
- …

Vistas múltiples

Mostrar cada variable por separado

	A	B	C	D	E
1	4	1	8	3	5
2	6	3	4	2	1
3	5	7	2	4	3
4	2	6	3	1	5



Problema: no muestra correlaciones

Scatterplot

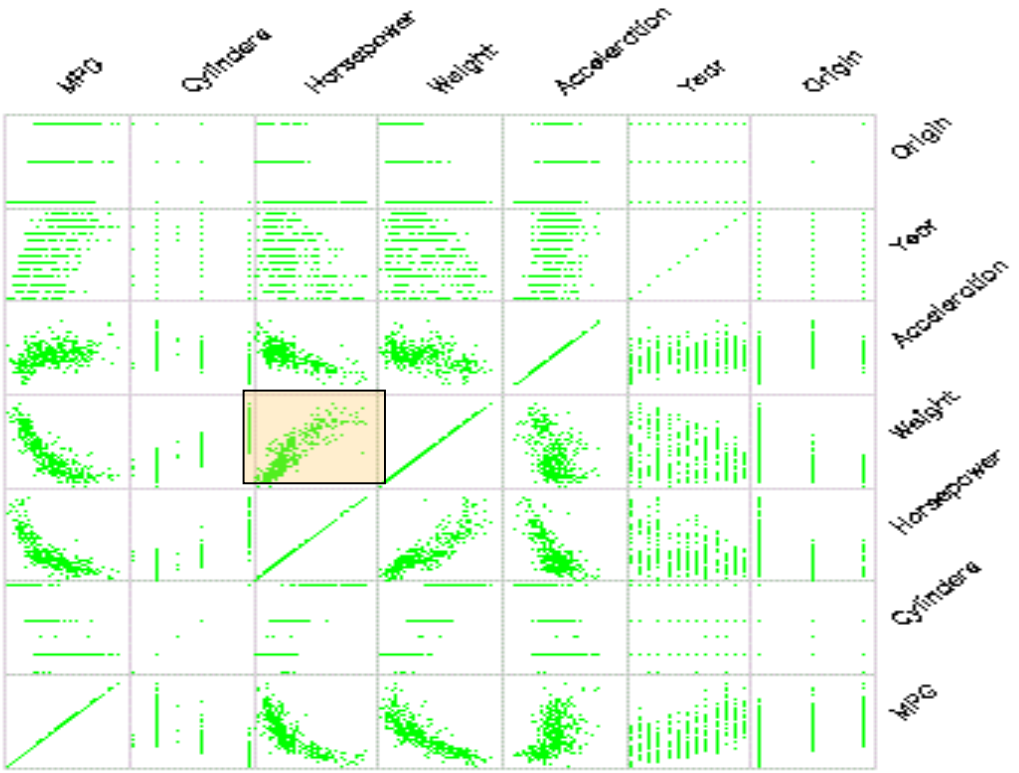
Muestra cada par de variables en un plot individual 2-D
Ejemplo: car data

Ventaja:

Se ven facilmente las correlaciones

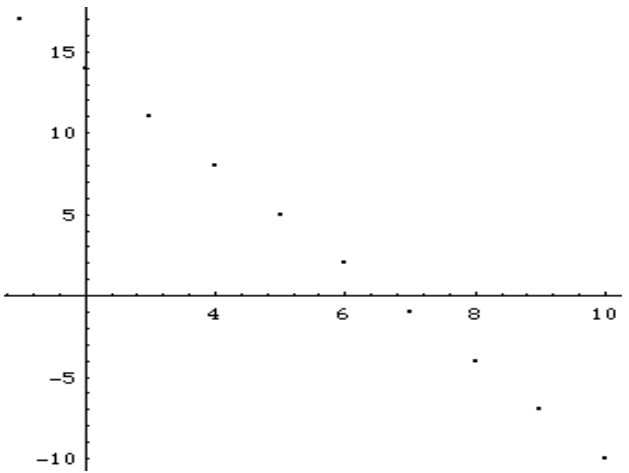
Problema:

No se ven los efectos multivariados

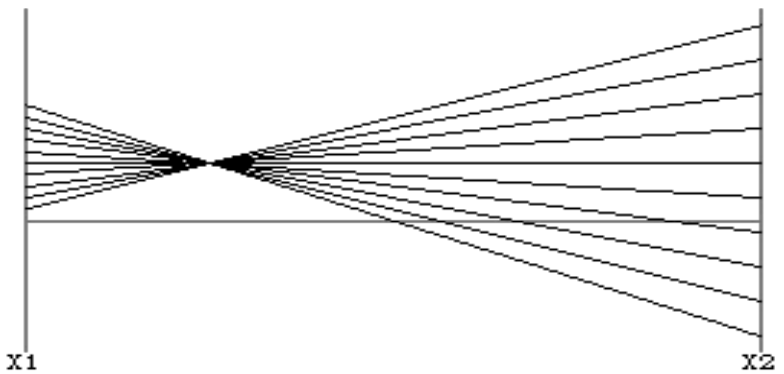


Parallel Coordinates

- Pone cada variable en un valor distinto (fijo) del eje horizontal.
- Los valores se ponen en la vertical, y se unen con líneas

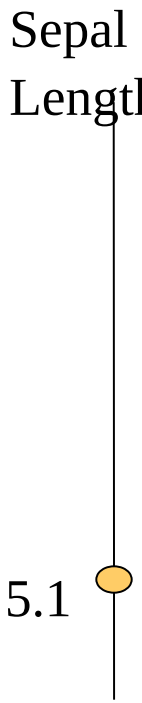


Un dataset en coordenadas Cartesianas



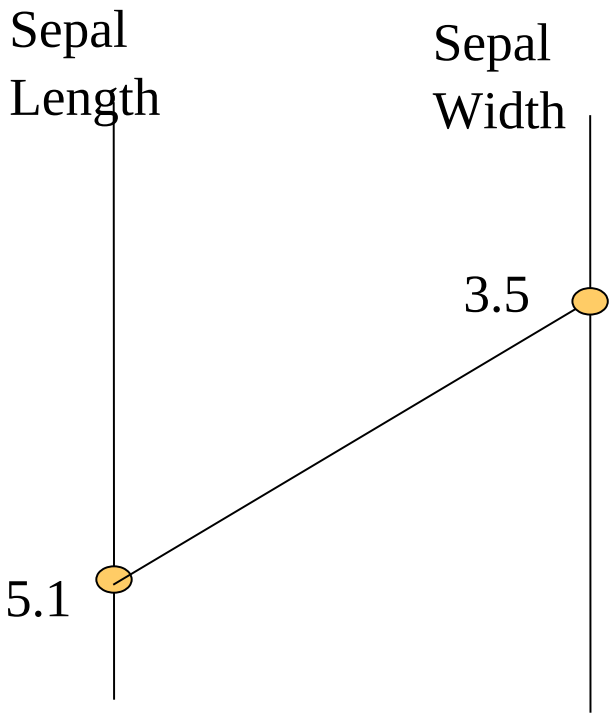
El mismo dataset en parallel coordinates

Parallel Coordinates: ejemplo



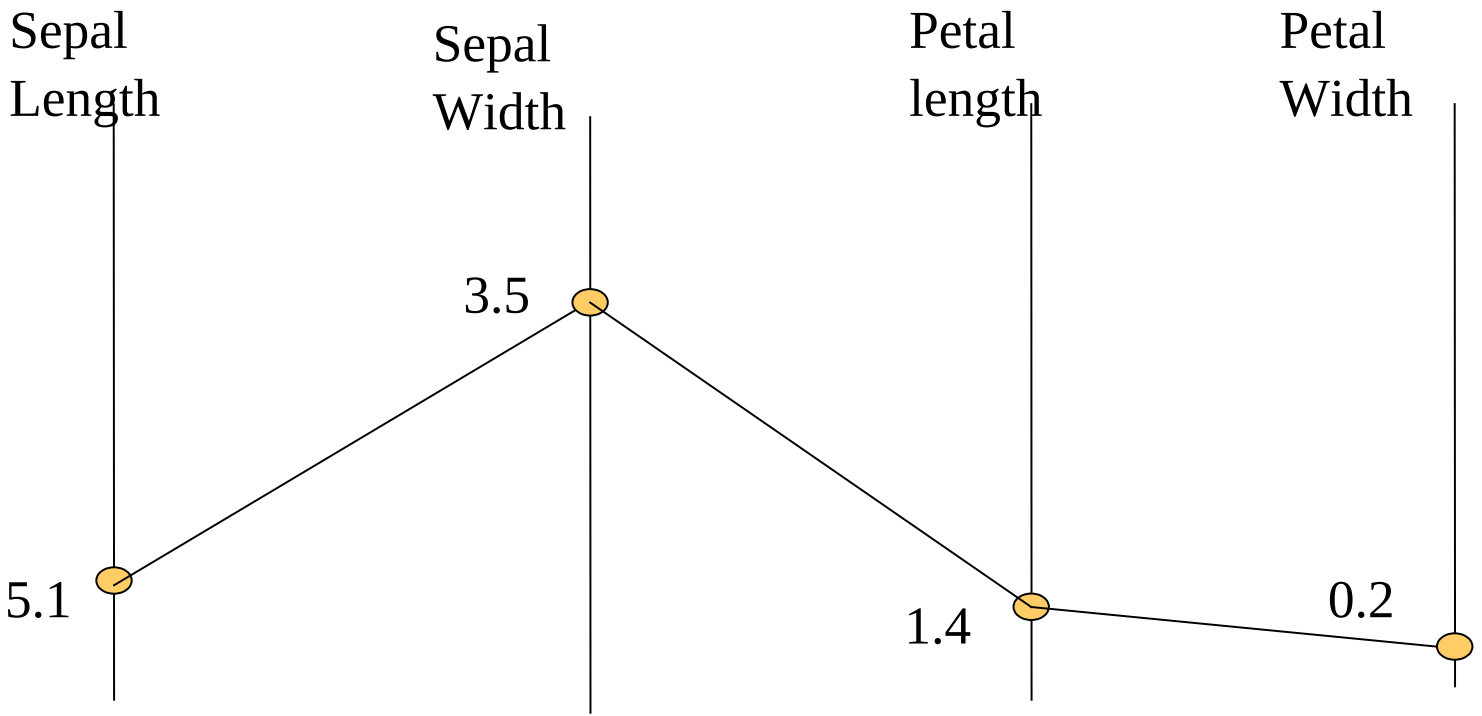
sepal length	sepal width	petal length	petal width
5.1	3.5	1.4	0.2

Parallel Coordinates: 2 D



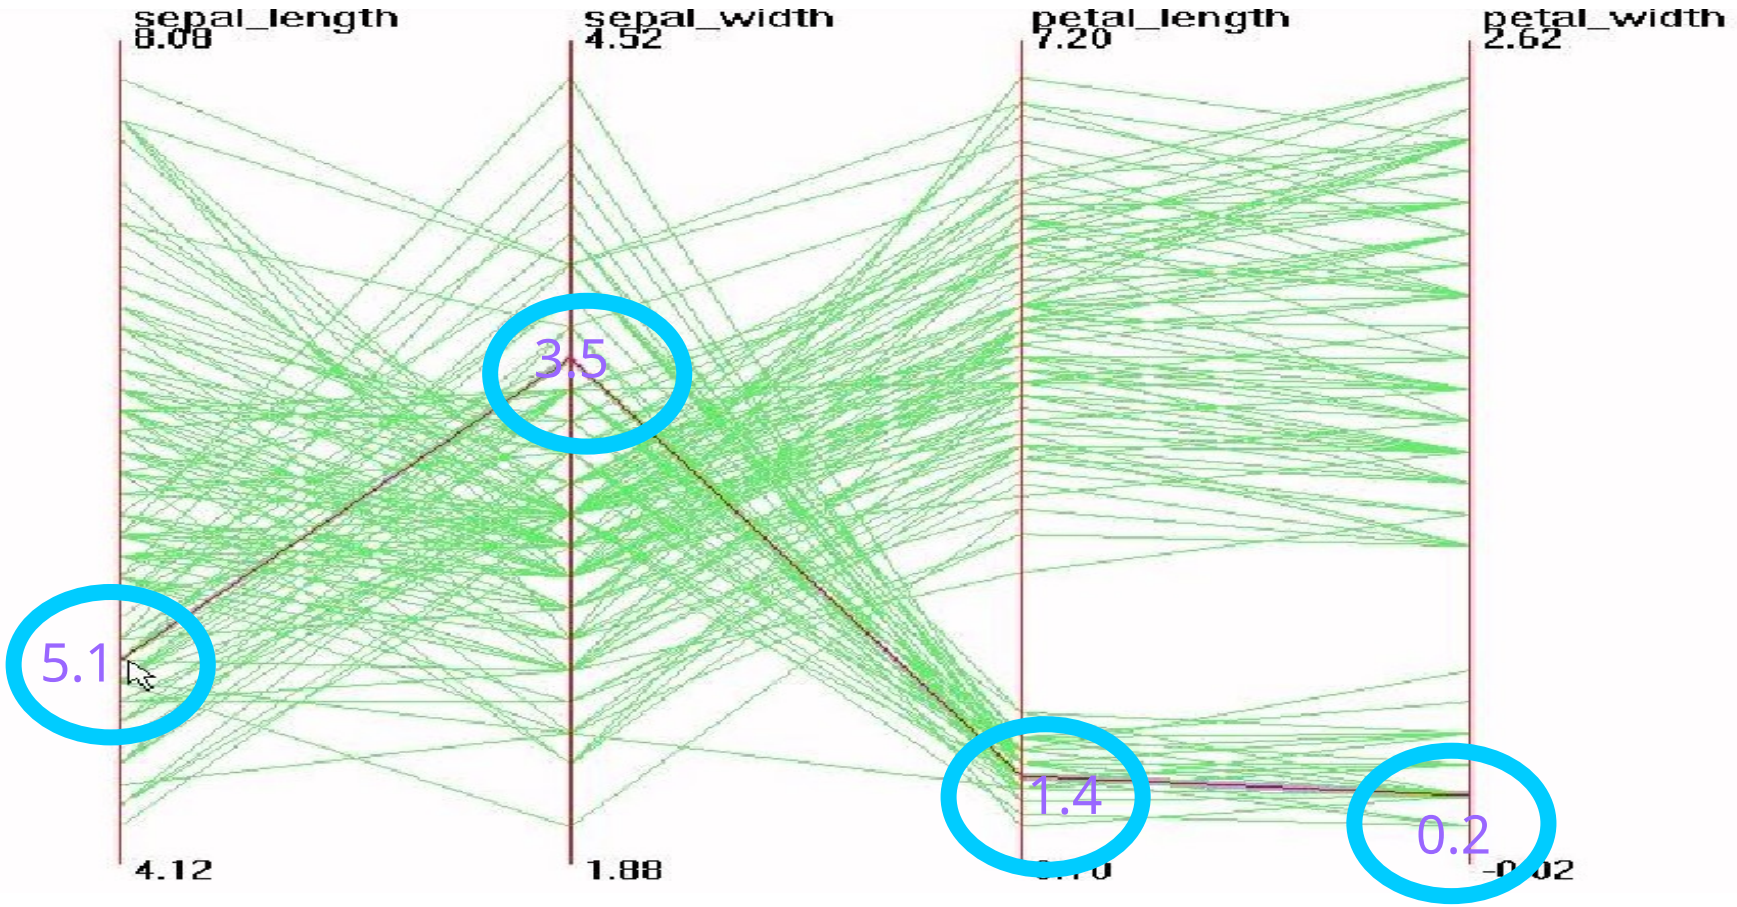
sepal length	sepal width	petal length	petal width
5.1	3.5	1.4	0.2

Parallel Coordinates: 4 D

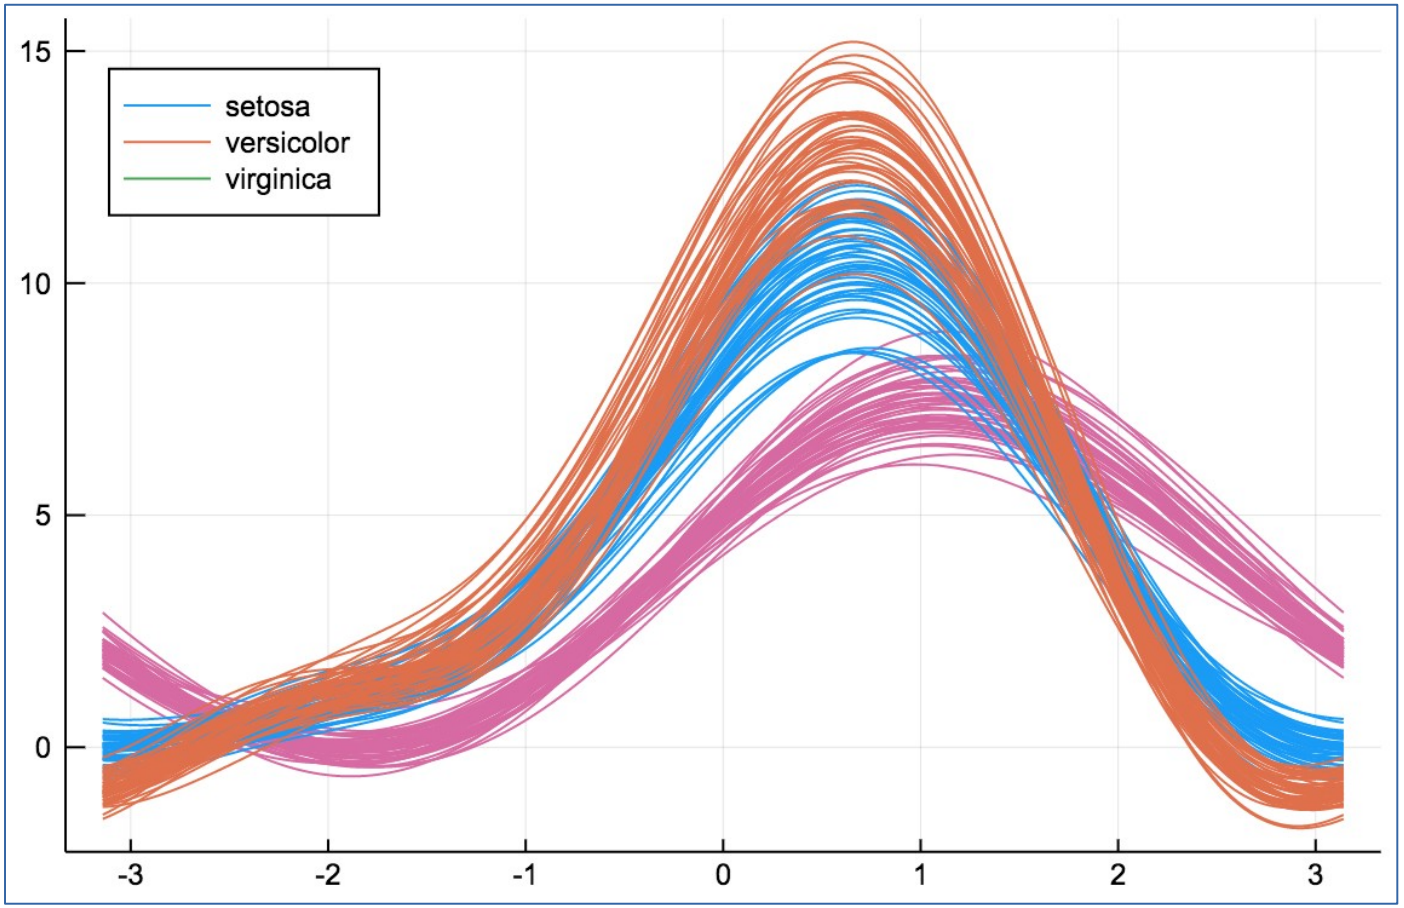


sepal length	sepal width	petal length	petal width
5.1	3.5	1.4	0.2

Parallel Coordinates: Iris



Andrews plots: Iris



Lo anterior,
pero suavizado

Parallel coordinates: resumen

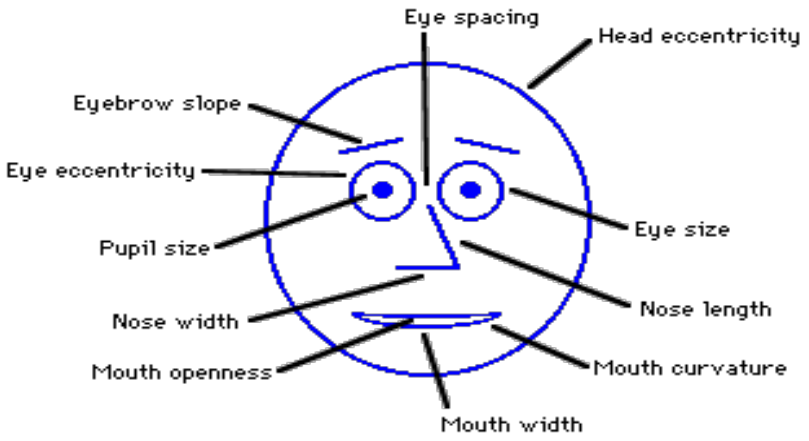
- Cada punto es una línea
- Puntos similares, líneas similares
- Las líneas que cruzan muestran atributos negativamente correlacionados

- Problemas:
  - el orden de los ejes es importante
  - Límite de ~20 dimensiones

Chernoff Faces

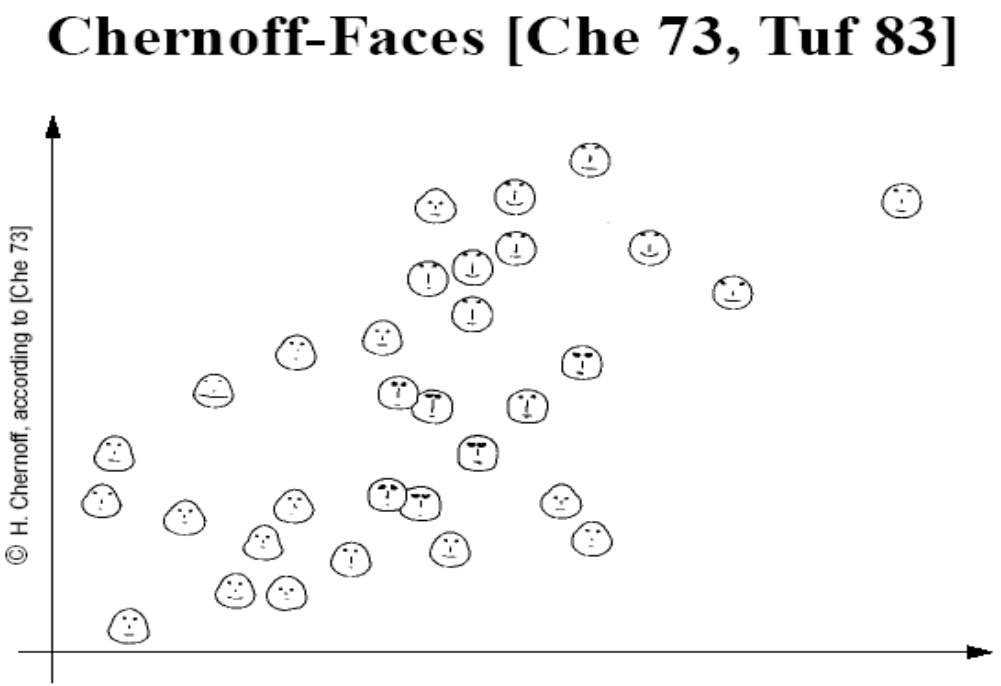
Codifica las diferentes variables en características de la cara humana

Aprovecha la capacidad humana de encontrar fácilmente pequeñas diferencias entre caras



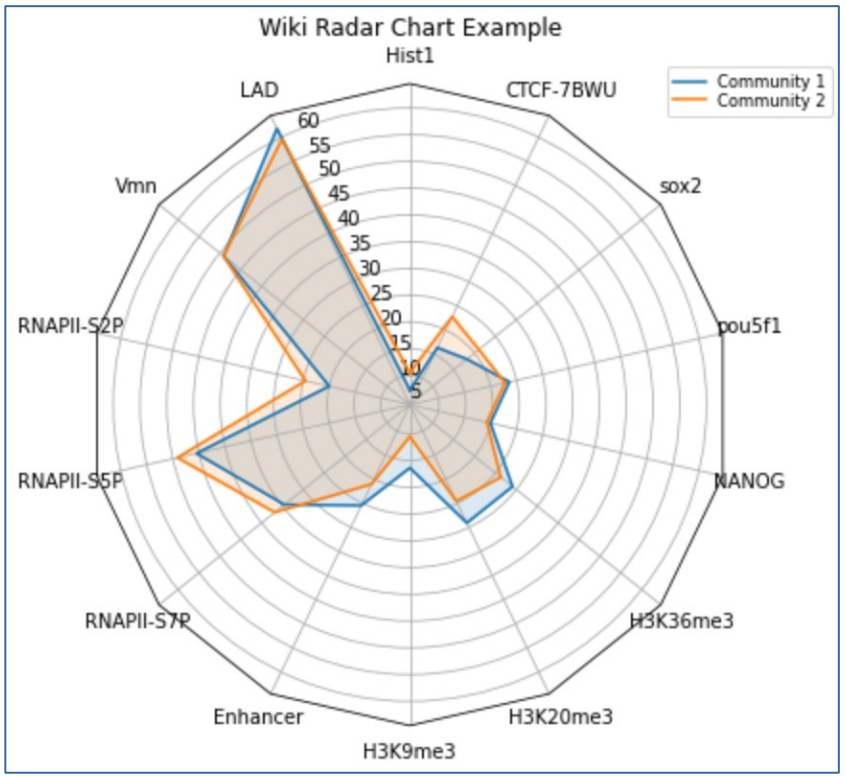
Applets: `http://www.cs.uchicago.edu/~wiseman/chernoff/`
`http://hesketh.com/schampeo/projects/Faces/chernoff.html`

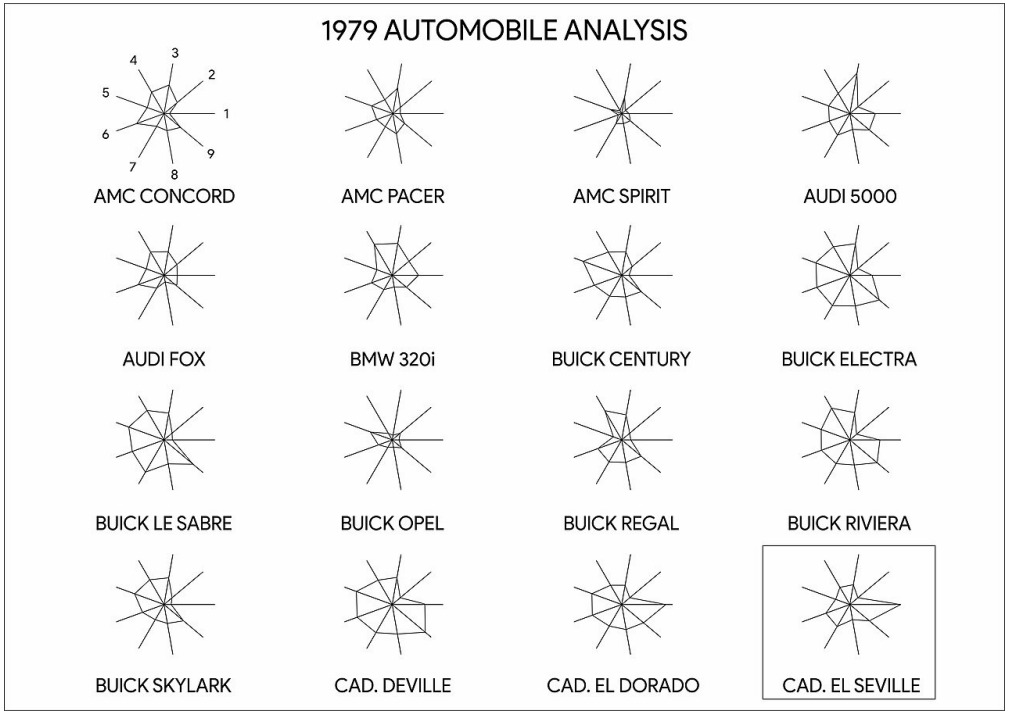
Chernoff faces, ejemplo



Stars plots (radar chart)

- Cada variable va en una dirección angular diferente. Cada punto forma una “estrella”





R: ejemplos

```
data(iris)

summary(iris)

plot(iris[,-5],col=iris[,5])

library(MASS)

parcoord(iris[,-5],col=iris[,5])

require(TeachingDemos)

faces(iris[,-5],ncol=25)
```

```
help(stars)

stars(iris[,-5],ncol=10, col.sta=iris[,5])


boxplot(iris[iris[,5]== "setosa",-5])

boxplot(iris[iris[,5]== "versicolor",-5])

boxplot(iris[iris[,5]== "virginica",-5])
```

Python: ejemplos

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from pandas.plotting import parallel_coordinates

# 1. Cargar el dataset 'iris'
iris = sns.load_dataset('iris')
# 2. summary(iris)
print(iris.describe(include='all'))
# 3. plot(iris[,-5], col=iris[,5]) - Matriz de dispersión coloreada por clase
sns.pairplot(iris, hue='species')
plt.show()
# 4. parcoord(iris[,-5], col=iris[,5]) - Coordenadas paralelas
plt.figure()
parallel_coordinates(iris, 'species', color=('#1f77b4', '#ff7f0e', '#2ca02c'))
plt.title("Parcoord (Coordenadas Paralelas)")
plt.show()
```

Python: ejemplos

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from pandas.plotting import parallel_coordina

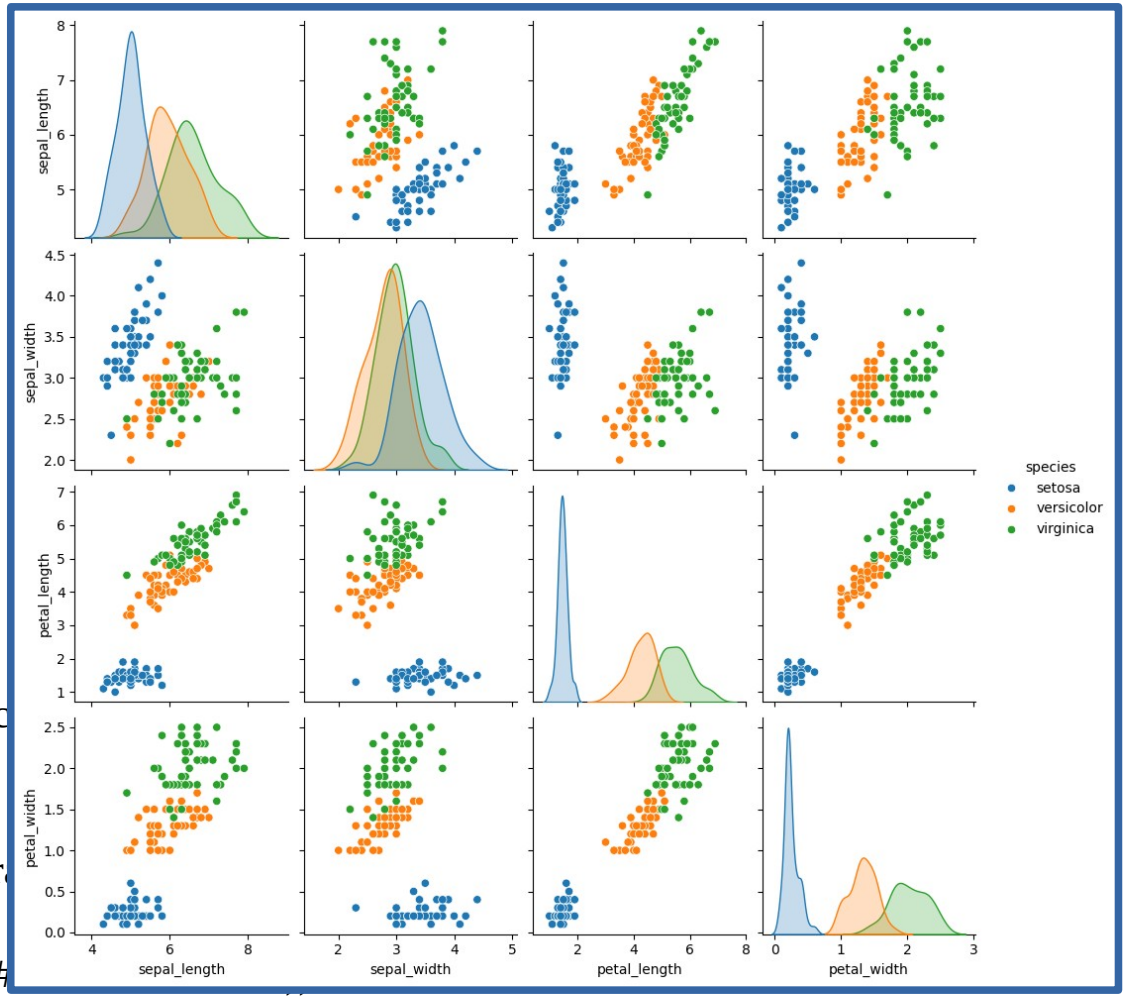
# 1. Cargar el dataset 'iris'
iris = sns.load_dataset('iris')
# 2. summary(iris)
print(iris.describe(include='all'))
# 3. plot(iris[,-5], col=iris[,5]) - Matriz de dispersión coloreada por clase
sns.pairplot(iris, hue='species')
plt.show()
# 4. parcoord(iris[,-5], col=iris[,5]) - Coordenadas paralelas
plt.figure()
parallel_coordinates(iris, 'species', color=('#1f77b4', '#ff7f0e', '#2ca02c'))
plt.title("Parcoord (Coordenadas Paralelas)")
plt.show()
```

```
...        sepal_length  sepal_width  petal_length  petal_width species
count        150.000000   150.000000    150.000000   150.000000     150
unique              NaN          NaN           NaN          NaN       3
top                 NaN          NaN           NaN          NaN  setosa
freq                NaN          NaN           NaN          NaN      50
mean           5.843333     3.057333      3.758000     1.199333     NaN
std            0.828066     0.435866      1.765298     0.762238     NaN
min            4.300000     2.000000      1.000000     0.100000     NaN
25%            5.100000     2.800000      1.600000     0.300000     NaN
50%            5.800000     3.000000      4.350000     1.300000     NaN
75%            6.400000     3.300000      5.100000     1.800000     NaN
max            7.900000     4.400000      6.900000     2.500000     NaN
```

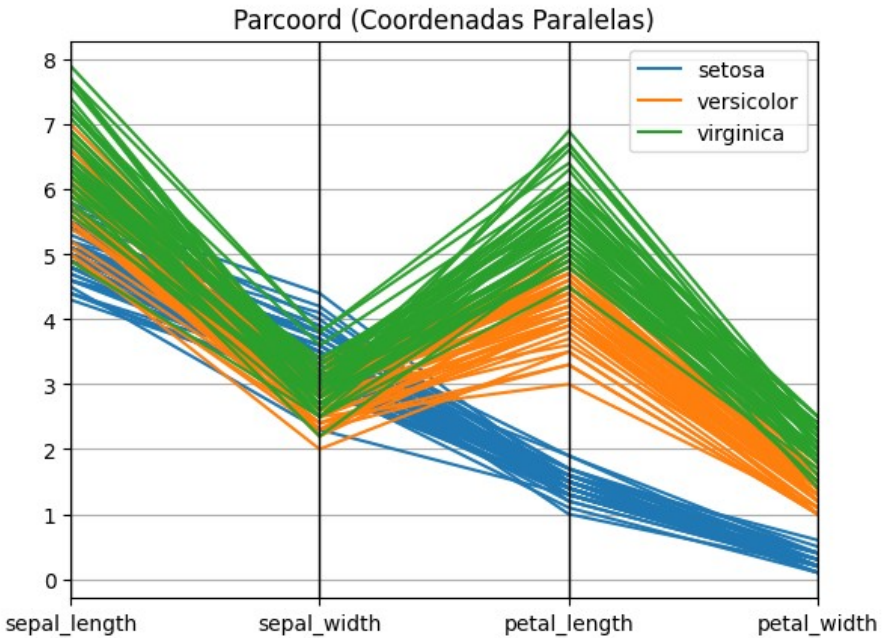
Python: ejemplos

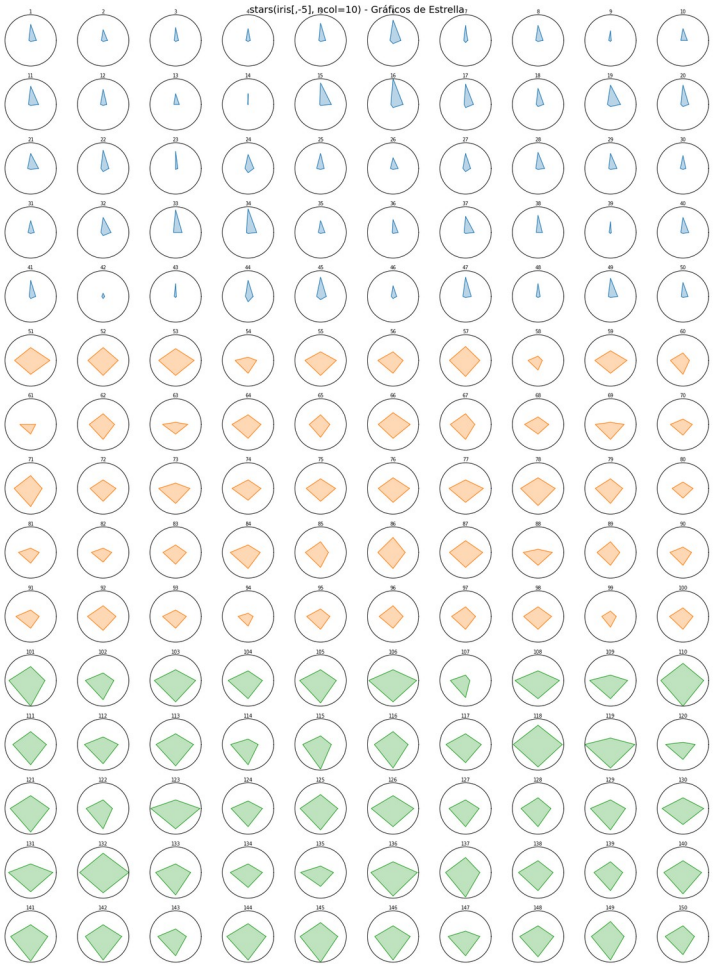
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from pandas.plotting import parallel_coordinates

# 1. Cargar el dataset 'iris'
iris = sns.load_dataset('iris')
# 2. summary(iris)
print(iris.describe(include='all'))
# 3. plot(iris[,-5], col=iris[,5]) - Matriz de dispersión c
sns.pairplot(iris, hue='species')
plt.show()
# 4. parcoord(iris[,-5], col=iris[,5]) - Coordenadas par
plt.figure()
parallel_coordinates(iris, 'species', color=('#1f77b4', '#
plt.title("Parcoord (Coordenadas Paralelas)")
plt.show()
```



Python: ejemplos





Resumen

- Muchos métodos, distintas ventajas
- Se pueden visualizar datos en más de 3-D
- Buscar siempre:
  - Hacer buenas gráficas
  - Que muestren la mayor cantidad de información
  - Que no mientan sobre los datos