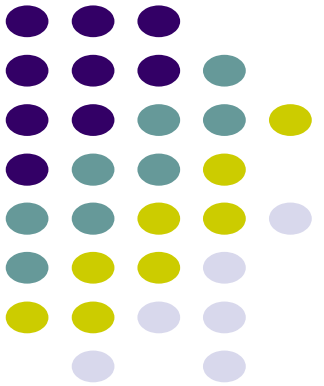
Selección de variables



Basado en parte en curso de I. Guyon

Entender nuestros datos



- Para resolver problemas con datos es importante entenderlos
- Visualizar es la primer opción
  - Visualizaciones directas
  - Proyecciones

¿Qué otra cosa puedo hacer para entender?

Entender nuestros datos



- Para resolver problemas con datos es importante entenderlos
- Visualizar es la primer opción
  - Visualizaciones directas
  - Proyecciones
- Crear modelos y entender cómo funcionan
  - Qué parte de los datos les resultan más difíciles
  - Qué variables de entrada (features) son relevantes

Selección de variables



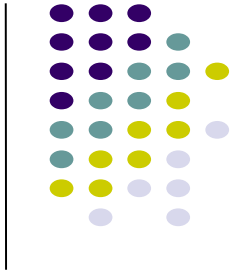
- Por qué y para qué?
- Métodos
- Filtros
- Wrappers
- RFE
- Cuántas variables dejar
- Estabilidad. Selección en listas múltiples

Selección de variables: Por qué?



- Muchos problemas actuales tienen cientos o miles de variables medidas (sobre pocos ejemplos)
- Modelar esos problemas “directamente” suele ser sub-óptimo.
  - Tanto en calidad como en interpretabilidad.
- En algunos casos la “extracción de variables” (pca, ica, etc.) no es una opción válida.

Selección de variables: Para qué?



- Para mejorar la performance de los métodos de aprendizaje:
  - Algunos métodos trabajan mucho mejor con menos variables.
    - Aunque los métodos modernos de ML suelen ser muy resistentes al problema de la dimensionalidad.
  - En ciertos casos muchas variables no son informativas del problema (ruido o redundancias).
    - Al eliminarlas reducimos el riesgo de sobreajuste.

Selección de variables: Para qué?



- Para descubrir:
  - Cuáles son las variables más importantes en un problema.
  - Cuáles variables están correlacionadas, co-reguladas, o son dependientes y cuáles no.

Selección de variables: Para qué?

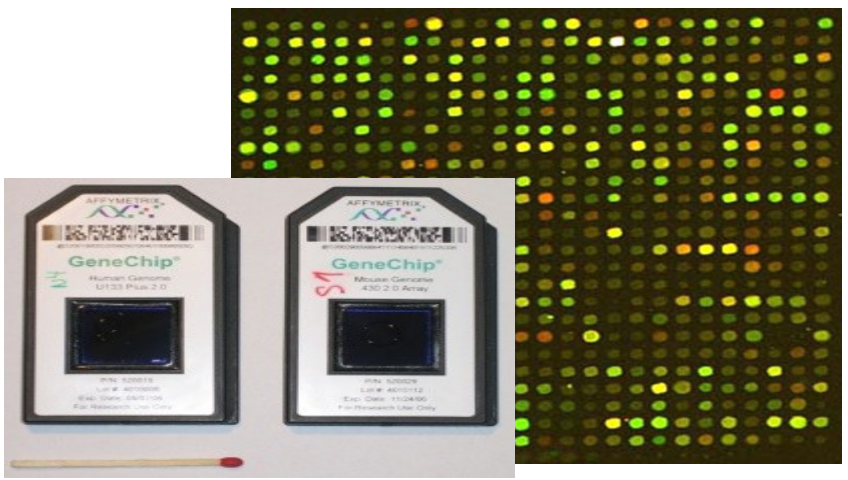


- Para descubrir:
  - Cuáles son las variables más importantes en un problema.
  - Cuáles variables están correlacionadas, co-reguladas, o son dependientes y cuáles no.

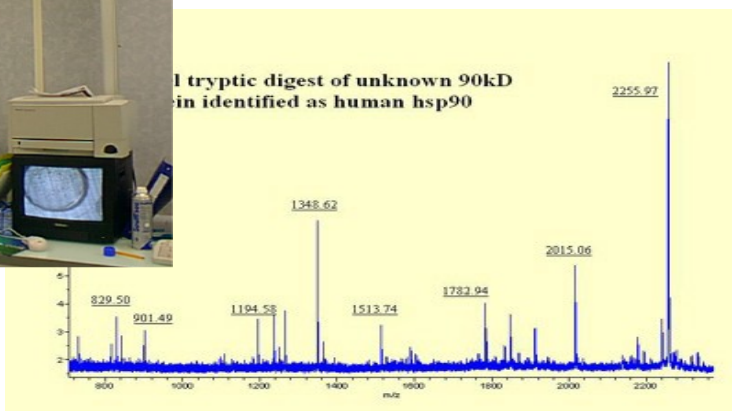
- La selección de variables no es más una técnica de pre-procesado, actualmente es una herramienta para descubrir información de un problema.

Ejemplos actuales

- Técnicas biológicas de “High throughput”
  - DNA Microchips (3000~12000 genes)
  - Mass Spectrometry (200~10000 picos)
  - Nunca más de ~100 muestras.

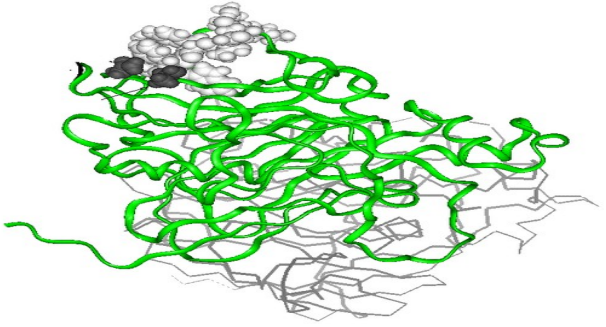


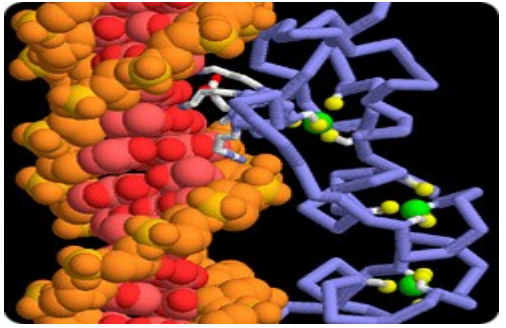




Ejemplos actuales

- QSAR
  - Relación cuantitativa entre estructura molecular y actividad del compuesto. Clave en la industria farmaceútica.
  - (100~2000) descriptores moleculares.





Métodos

- **Problema Base:**

  Seleccionar un subconjunto óptimo de (r) variables de las p variables originales, dado un criterio.

- Por qué no evaluar todas las posibilidades?

  Explosión combinatoria: $$\sum_{r=1}^{p} C_r^p = \sum_{r=1}^{p} \frac{p!}{r!(p-r)!}$$

Se usan soluciones sub-óptimas sobre eurísticas.

Cómo elegir variables?

- Qué cosas sería razonable intentar?



Métodos



- **Univariados** consideran una variable a la vez.
- **Multivariados:** consideran subconjuntos de variables al mismo tiempo.
- **Filtros:** Ordenan las variables con criterios de importancia independientes del predictor.
- **Wrappers:** Usan el predictor final para evaluar la utilidad de las variables.

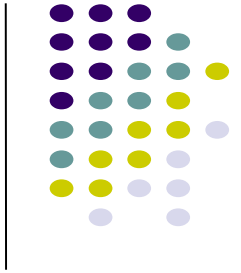
Métodos

- **Univariados** consideran una variable a la vez.
- **Multivariados:** consideran subconjuntos de variables al mismo tiempo.
- **Filtros:** Ordenan las variables con criterios de importancia independientes del predictor.
- **Wrappers:** Usan el predictor final para evaluar la utilidad de las variables.

Métodos

- **Univariados** consideran una variable a la vez.
- **Multivariados:** consideran subconjuntos de variables al mismo tiempo.
- **Filtros:** Ordenan las variables con criterios de importancia independientes del predictor.
- **Wrappers:** Usan el predictor final para evaluar la utilidad de las variables.

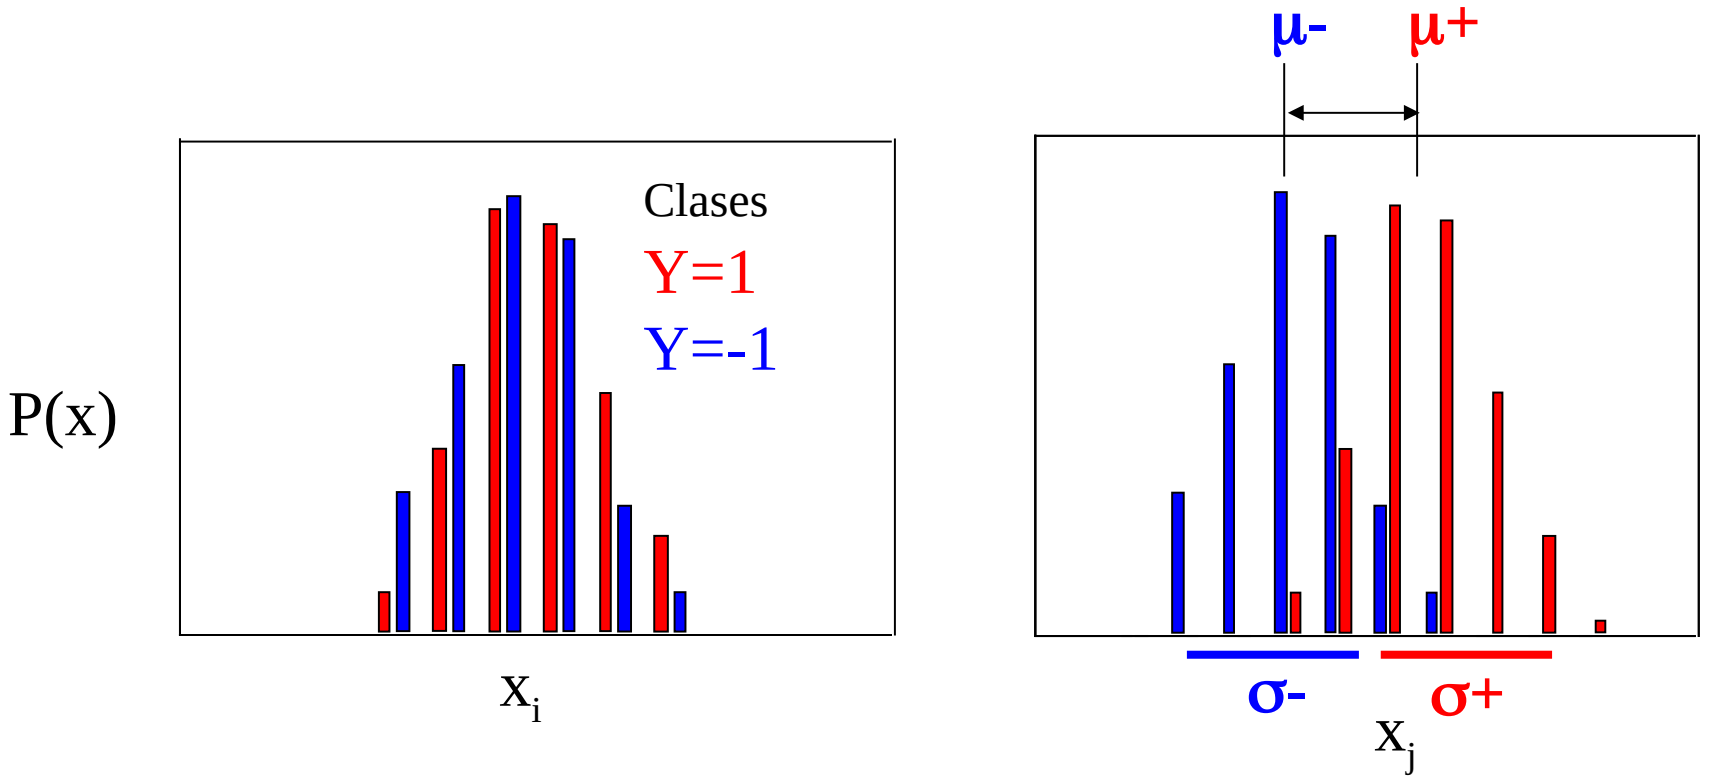
Métodos de Filtro



- Elige las mejores variables usando criterios razonables de “importancia”.
- El criterio es preferiblemente independiente del que se usará para modelar.
- Usualmente se usan criterios univariados.
- Se ordenan las variables en base al criterio y se retienen las más importantes (criterio de corte!)

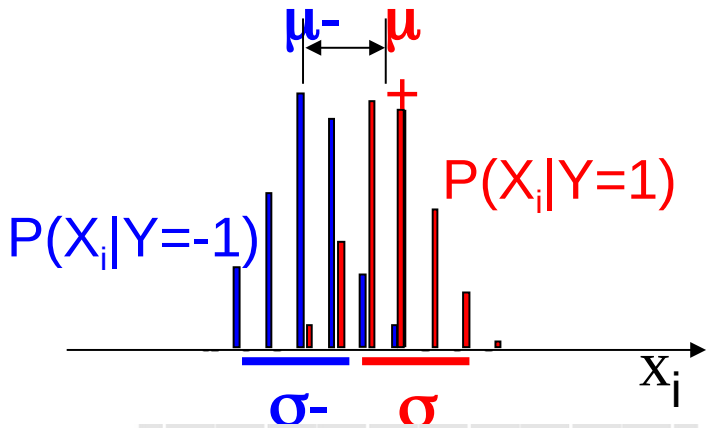
Métodos de Filtro: ejemplos

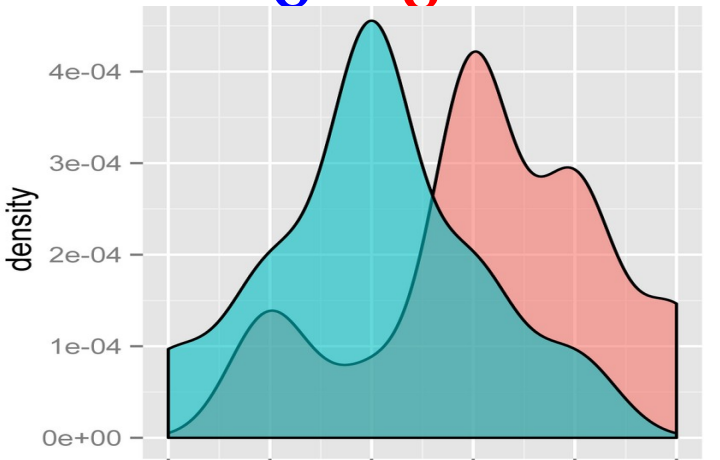
- Clasificación: Relevantes e Irrelevantes



Métodos de Filtro: ejemplos de criterios

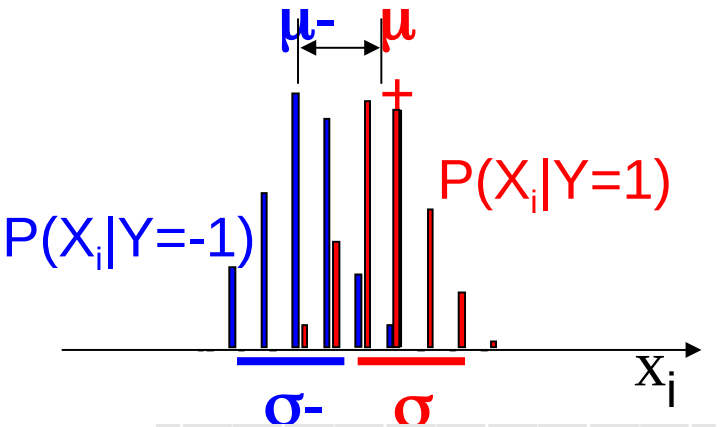
- Clasificación:
  - ANOVA: similar a la significancia de un t-test entre las clases dada la variable.
  - Ganancia de información sobre la clase dada la variable
  - Muchos otros (Relief!)
  - Kruskal-Wallis: Test no-paramétrico. No asume una distribución. Compara el orden de los valores por clase

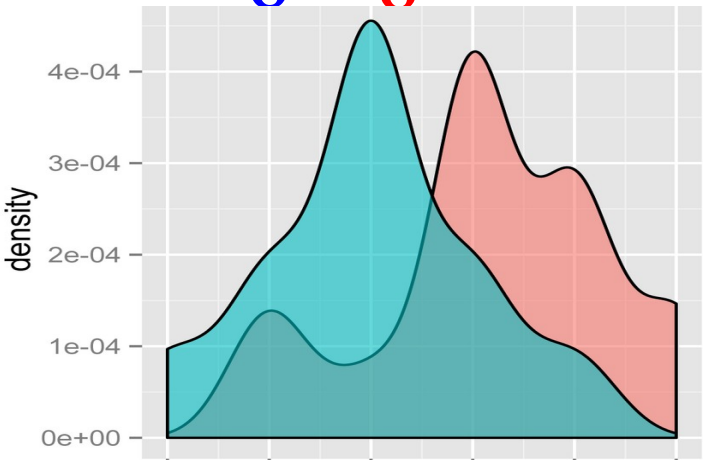




Métodos de Filtro: ejemplos de criterios

- ¿Parametrico o no-paramétrico?
  - Si tengo información segura sobre la distribución, siempre es mejor usar el modelo correcto
  - Si no estoy seguro, los test no-paramétricos pueden detectar diferencias en cualquier distribución (menos sensibles)





Métodos de Filtro: ejemplos

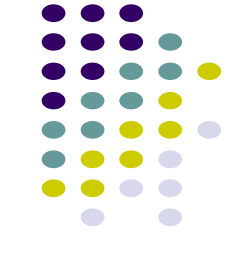


```
from sklearn.datasets import load_iris
# Carga de Dataset Iris
iris = load_iris()
X = iris['data']
y = iris['target']
print(X.shape)
```

```
(150, 4)
```

```
from scipy.stats import f_oneway
for i in range(4):
    x = X[:, i]
    print(f_oneway(x, y).statistic)
from scipy.stats import kruskal
for i in range(4):
    x = X[:, i]
    print(kruskal(x, y).statistic)
```

Métodos de Filtro: ejemplos



```
from scipy.stats import f_oneway
for i in range(4):
    x = X[:, i]
    print(f_oneway(x, y).statistic)
```

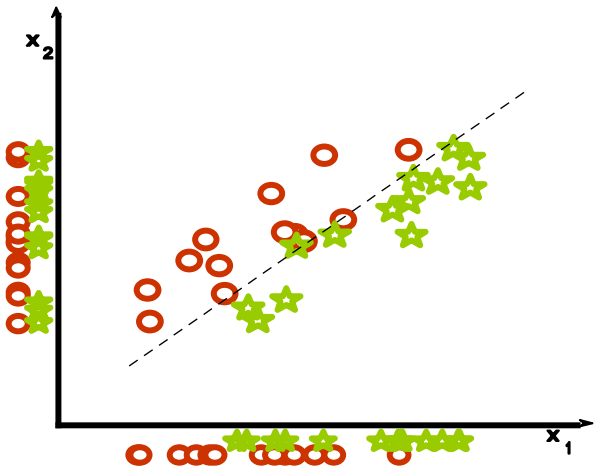
```
2593.302124467235
737.2872570149495
301.2565186681307
4.759876993399074
```

```
from scipy.stats import kruskal
for i in range(4):
    x = X[:, i]
    print(kruskal(x, y).statistic)
```

```
227.4622214919089
226.70933994189542
136.85995230072515
10.189974452513676
```

Multivariados

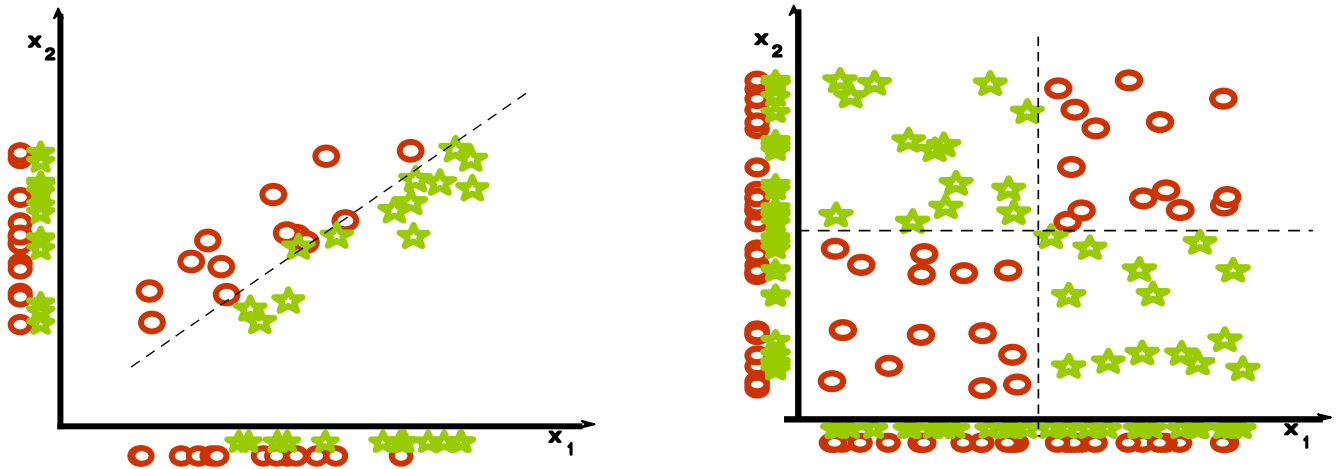
- Los métodos univariados no pueden resolver algunos problemas



Guyon-Elisseeff, JMLR 2004; Springer 2006

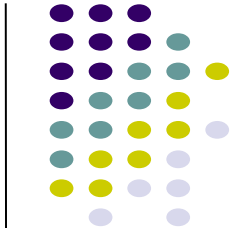
Multivariados

- Los métodos univariados no pueden resolver algunos problemas



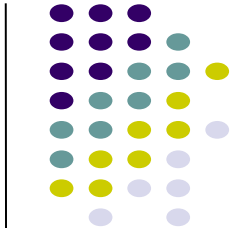
Guyon-Elisseeff, JMLR 2004; Springer 2006

Wrappers. Claves



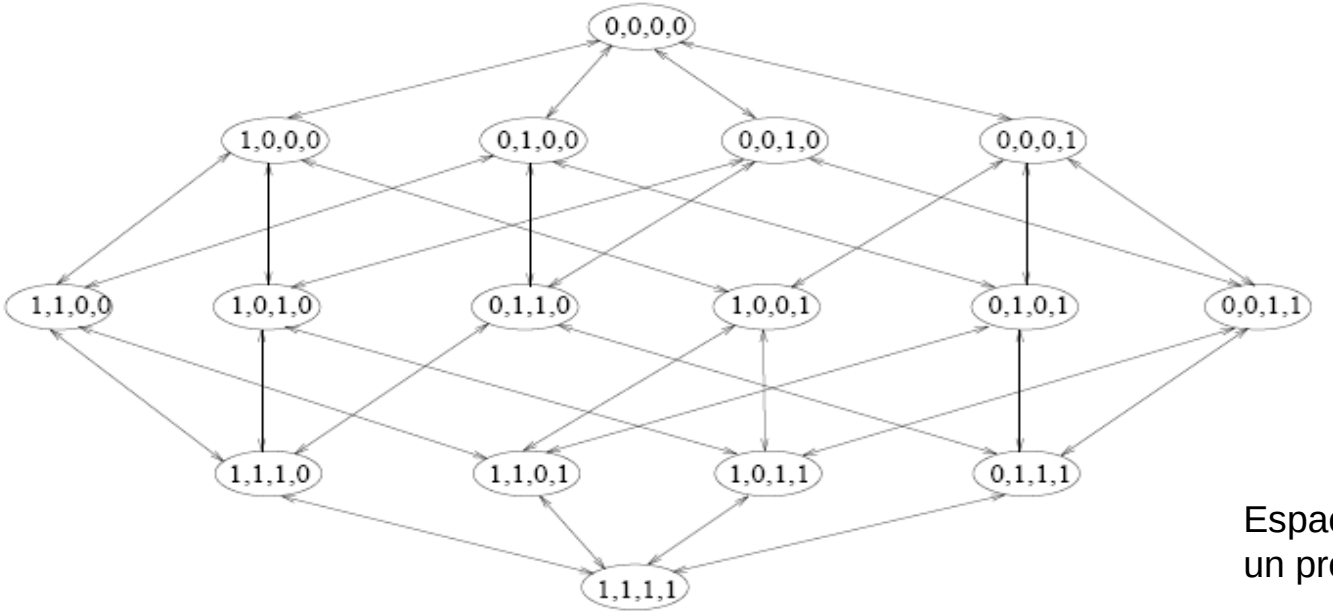
- Seleccionar las mejores variables para modelar (usando el criterio final)
- Para cada subconjunto de variables resolver el problema de modelado. Conservar la mejor solución.
- Como ya discutimos, la búsqueda completa es exponencialmente larga.

Wrappers. Alternativas



- Búsquedas Greedy:
  - forward selection
  - backward elimination
  - combinaciones de ambas
- Búsquedas pseudo-random:
  - Simulated annealing
  - genetic algorithm

Wrappers. Ejemplo

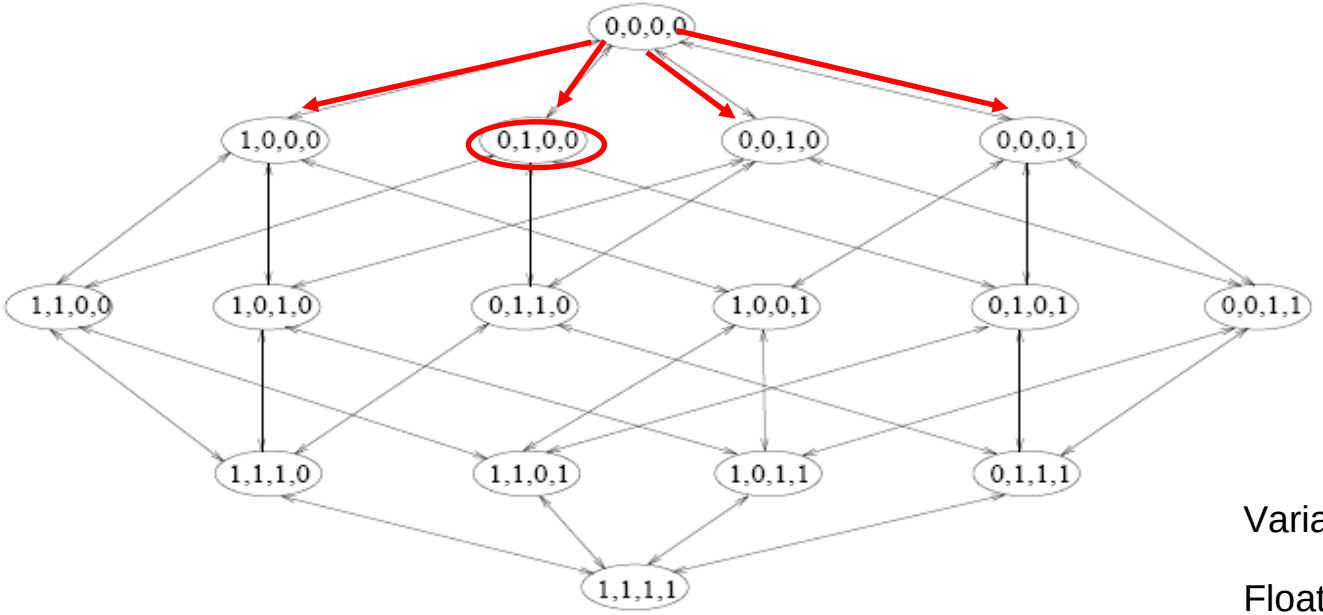


Kohavi-John, 1997

Espacio de búsqueda para un problema con 4 variables.

0 ausente - 1 presente

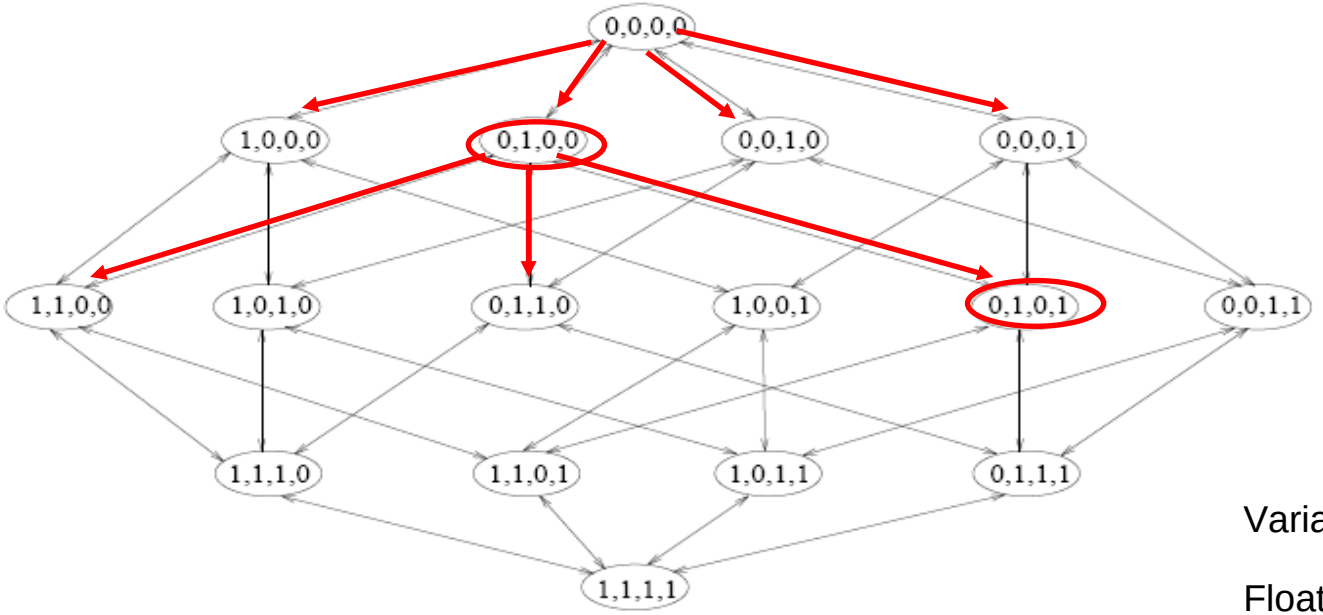
Wrappers. Forward search



Variantes:

Floating search. 1 paso adelante, 1 atrás

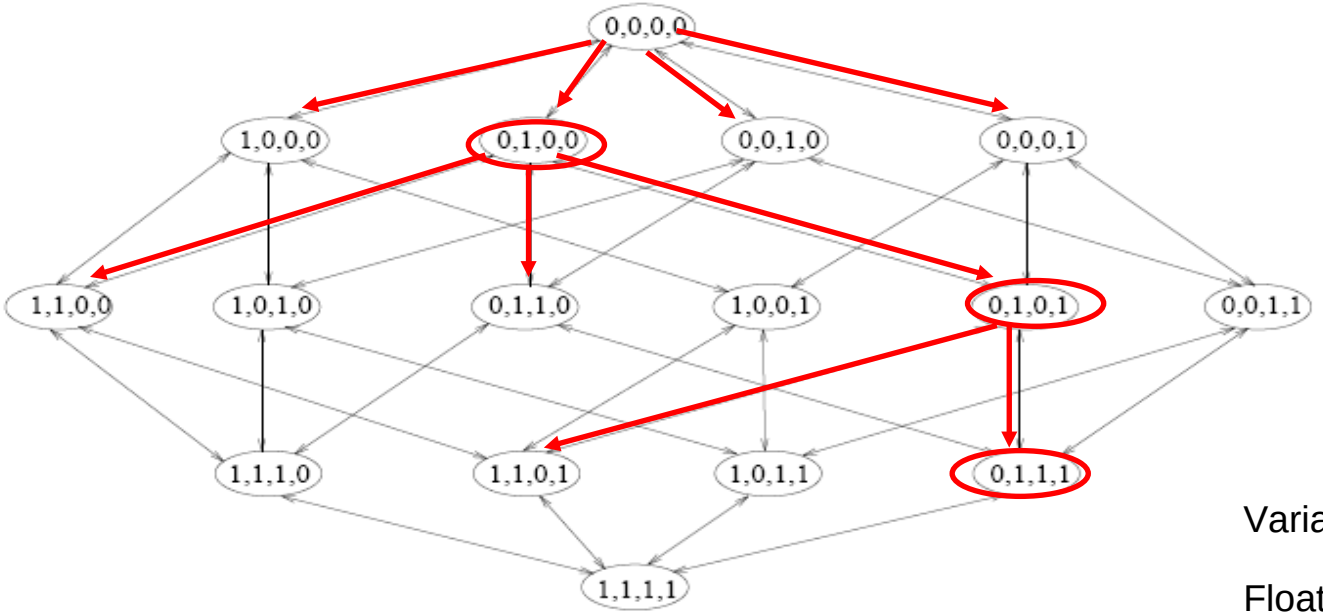
Wrappers. Forward search



Variantes:

Floating search. 1 paso adelante, 1 atrás

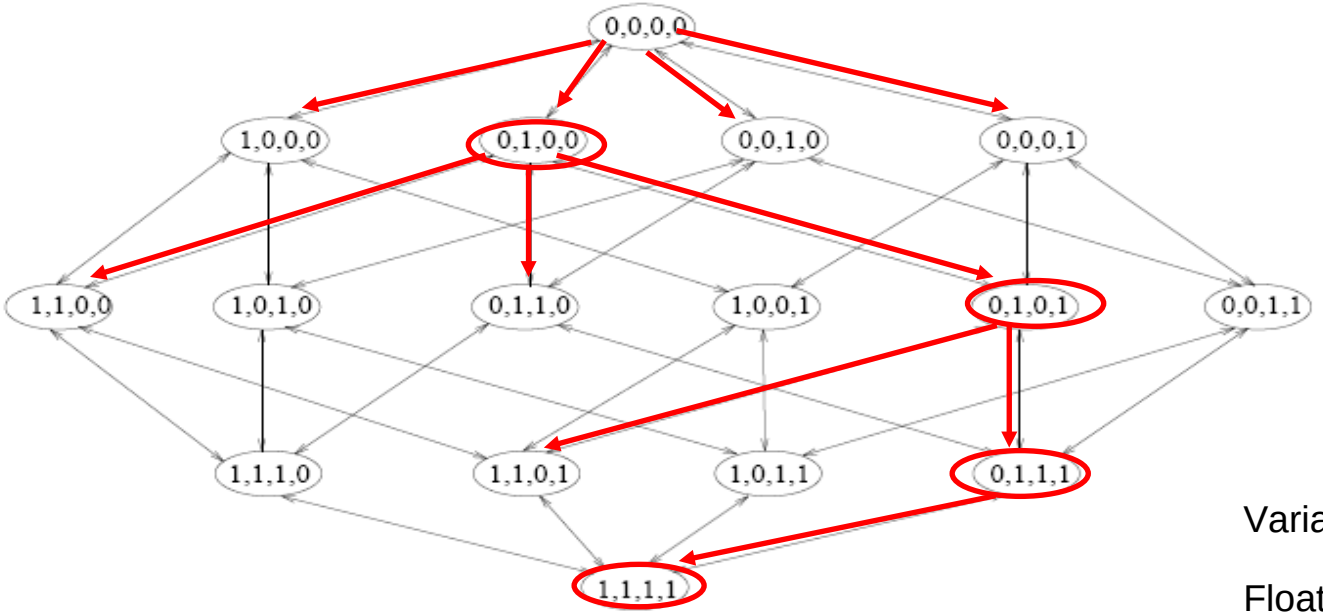
Wrappers. Forward search



Variantes:

Floating search. 1 paso adelante, 1 atrás

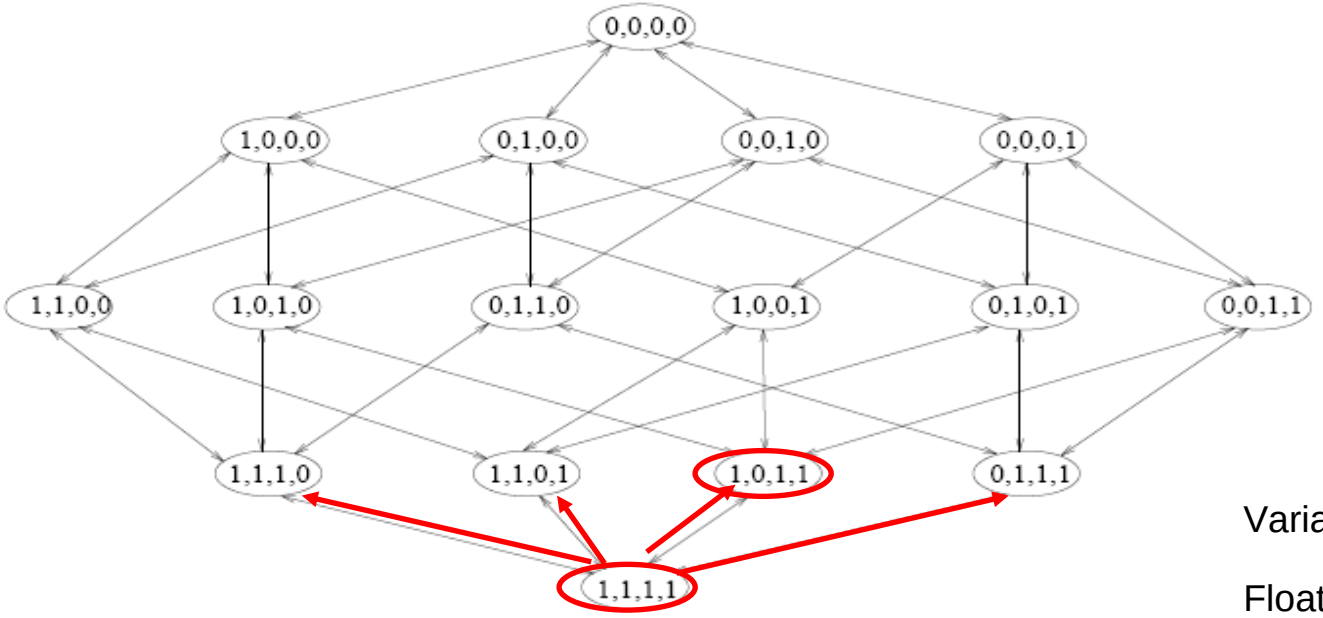
Wrappers. Forward search



Variantes:

Floating search. 1 paso adelante, 1 atrás

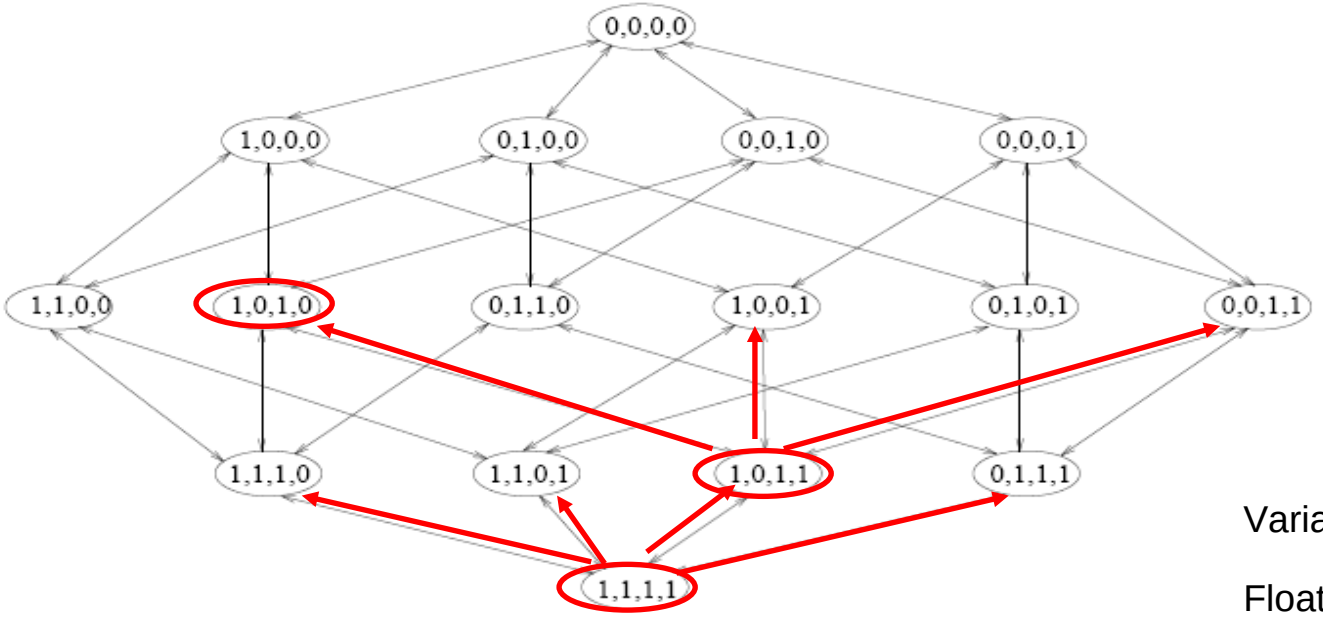
Wrappers. Backward search



Variantes:

Floating search

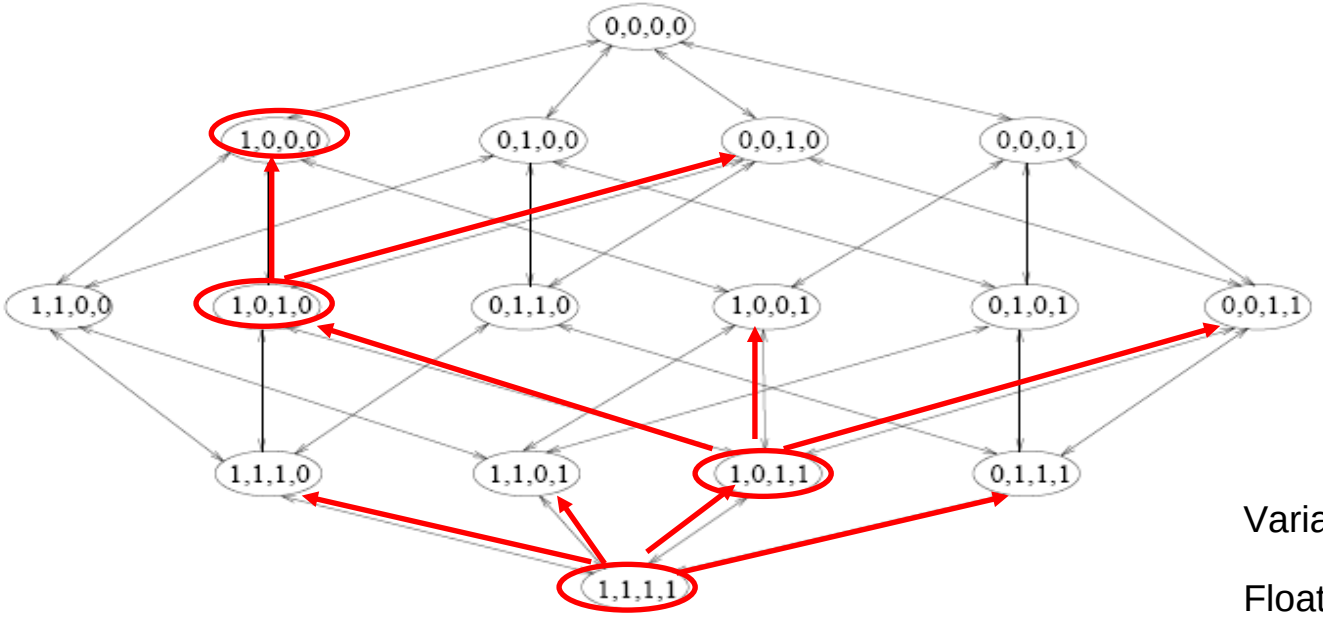
Wrappers. Backward search



Variantes:

Floating search

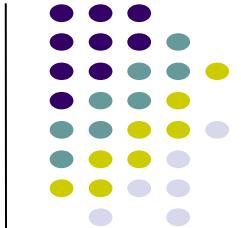
Wrappers. Backward search



Variantes:

Floating search

Wrappers. Problemas



- Forward no evalúa las interacciones
  - Pero puede encontrar un buen conjunto muy chico de variables
- Muy caro computacionalmente
  - Requiere ajustar un modelo completo para cada caso
  - Dadas p variables, es de $O(p^2)$
- Suele sobreajustar la solución con conjuntos chicos
  - La búsqueda hill-climbing es muy agresiva

Filtros vs. wrappers



- Los dos son heurísticas
- Los filtros:
  - No resuelven el problema de modelado directamente.
  - Suelen tener problemas con variables “conjuntas”
  - Son muy rápidos
- Los wrappers
  - Dan mejores selecciones
  - Son muy pesados
  - Suelen hacer overfitting